

Appunti Tirocinio

Alessio Marini

Appunti presi per il mio Tirocinio interno presso il Vision-Lab.

August 05, 2026

1. Linear Algebra

1.1. Scalars

I numeri che utilizziamo tutti i giorni prendono il nome di **scalari**, li indicheremo con lettere *lower-case* come x, y, z e lo spazio di tutti gli scalari **reali** $\mathbb{R}$.

Implementiamo gli scalari come dei tensor da un solo elemento, vediamo un esempio di assegnamento e delle operazioni:

```
x = torch.tensor(3.0)
y = torch.tensor(2.0)

x + y, x * y, x / y, x**y
# Output
# (tensor(5.), tensor(6.), tensor(1.5000), tensor(9.))
```

1.2. Vectors

Possiamo vedere i vettori come degli array di scalari con lunghezza fissa, gli scalari saranno gli *elementi* del vettore. Quando li utilizzeremo per rappresentare problemi reali avremo che ogni elemento indica un parametro di cosa stiamo analizzando. Indichiamo i vettore con lettere lowercase bold come $\mathbf{x}, \mathbf{y}, \mathbf{z}$.

Ci riferiamo agli elementi di un vettore con la lettera del vettore e l'indice dell'elemento in basse, x_2 indica l'elemento con indice 2 nel vettore $\mathbf{x}$. Normalmente li visualizziamo impilando gli elementi verticalmente:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_3 \end{bmatrix}$$

Per indicare che un vettore contiene n elementi scriviamo che $\mathbf{x} \in \mathbb{R}^n$, formalmente diciamo che n è la **dimensione** dell'array, questa nel codice corrisponde appunto alla lunghezza del tensor che possiamo richiamare con `len(x)` oppure tramite l'attributo `x.shape`.

Per fare chiarezza indichiamo con:

- **Order**: Numero degli assi di un vettore
- **Dimensionality**: Numeri dei componenti

1.3. Matrici

Gli scalari sono tensor di ordine 0, i vettori sono tensor di ordine 1 e le matrici sono di ordine 2. Le indichiamo con lettere upper case bold, quindi $\mathbf{X}, \mathbf{Y}, \mathbf{Z}$ e le rappresentiamo nel codice con vettori con due assi. Con l'espressione $\mathbf{A} \in \mathbb{R}^{m \times n}$ indichiamo che una matrice $\mathbf{A}$ contiene $m \times n$ valori reali ordinati in m righe e n colonne. Quando $m = n$ diciamo che la matrice è *quadrata*. Possiamo illustrarla come una tabella e per indicare un elemento usiamo il doppio pedice, quindi $a_{i,j}$ indica l'elemento nella i -esima riga e alla j -esima colonna di $\mathbf{A}$.

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

É possibile invertire gli assi ovvero scambiare righe con colonne, il risultato é la **matrice trasposta**, la indichiamo con $\mathbf{A}^\top$. Otteniamo che se $\mathbf{B} = \mathbf{A}^\top$ allora $b_{ij} = a_{ji}$ per ogni i, j . Inoltre la trasposta di una matrice $m \times n$ sar  una matrice $n \times m$.

Le matrici **simmetriche** sono un sottoinsieme delle matrici quadrate, sono matrici uguali alla loro trasposta, quindi $\mathbf{A} = \mathbf{A}^\top$

1.4. Tensors

I tensors ci danno modo di rappresentare array di ordine n . Li indichiamo con lettere maiuscole X,Y,Z e per gli elementi utilizziamo lo stesso meccanismo di indici delle matrici. I tensors diventeranno pi  importanti quando lavoreremo con le immagini, ognuna infatti é rappresentata da un tensor di ordine 3 dove gli assi corrispondono a *altezza*, *larghezza* e *canali*. Una collezione di immagini sar  quindi un tensor di ordine 4.

1.4.1. Basic Properties of Tensor Arithmetic

Scalari, vettori, matrici e tensors hanno delle propriet , ad esempio le operazioni *element-wise* producono output della stessa forma degli operandi.

```
A = torch.arange(6, dtype=torch.float32).reshape(2, 3)
B = A.clone() # Alloca nuova memoria per B
A, A + B

# Output
# (tensor([[0., 1., 2.],
#          [3., 4., 5.]]),
#  tensor([[ 0.,  2.,  4.],
#          [ 6.,  8., 10.]])
```

Il prodotto *elementwise* di due matrici si chiama **Hadamard Product**, lo indichiamo con $\odot$. Gli elementi saranno quindi:

$$\mathbf{A} \odot \mathbf{B} = \begin{bmatrix} a_{11}b_{11} & a_{12}b_{12} & \dots & a_{1n}b_{1n} \\ a_{21}b_{21} & a_{22}b_{22} & \dots & a_{2n}b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}b_{m1} & a_{m2}b_{m2} & \dots & a_{mn}b_{mn} \end{bmatrix}$$

Andando invece a sommare o moltiplicare un tensor con uno scalare otteniamo un tensor con la stessa forma di quello originale ma su ogni elemento viene applicata l'operazione specificata.

1.4.2. Reduction

Spesso ci capiter  di dover calcolare la somma di tutti gli elementi di un tensor. Matematicamente possiamo esprimerla come $\sum_{i=1}^n x_i$ ma nel codice esiste una funzione dedicata:

```
x = torch.arange(3, dtype=torch.float32)
x, x.sum()
```

```
# Output
# (tensor([0., 1., 2.]), tensor(3.))
```

La funzione `sum()` va bene anche per tensors di ordine maggiore. Di base chiamare la funzione somma, *riduce* il tensor su tutti i suoi assi producendo, in alcuni casi, uno scalare. Possiamo specificare su quali assi effettuare la somma e quell'asse ovviamente sparirà dalla dimensione del tensor:

```
A.shape, A.sum(axis=0).shape
# Output
# (torch.Size([2, 3]), torch.Size([3]))

A.shape, A.sum(axis=1).shape
# Output
# (torch.Size([2, 3]), torch.Size([2]))
```

In alcuni casi però potrebbe essere utile si calcolare la somma, ma anche mantenere intatto il tensor, in questi casi impostiamo:

```
sum_A = A.sum(axis=1, keepdims=True)
sum_A, sum_A.shape

# Output
# (tensor([[ 3.],
#          [12.]]),
# torch.Size([2, 1]))
```

1.4.3. Dot Products

È una delle operazioni principali, dati due vettori $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ il loro *dot product* è dato da $\mathbf{x}^\top \mathbf{y}$, ovvero la somma dei prodotti degli elementi nella stessa posizione:

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i$$

```
y = torch.ones(3, dtype = torch.float32)
x, y, torch.dot(x, y)

# Output
# (tensor([0., 1., 2.]), tensor([1., 1., 1.]), tensor(3.))
```

In modo perfettamente equivalente possiamo calcolare un dot product effettuando prima un prodotto elementwise e poi una somma.

I dot product sono fondamentali in questo ambito. Ad esempio dato un set di valori in un vettore $\mathbf{x} \in \mathbb{R}^n$ e un set di pesi $\mathbf{w} \in \mathbb{R}^n$; la *weighted sum* di $\mathbf{x}$ in base ai pesi $\mathbf{w}$ può essere espressa come il dot product $\mathbf{x}^\top \mathbf{w}$.

Quando i pesi sono non negati e la loro somma è uguale a 1, il dot product rappresenta una *weighted average*. Inoltre, dopo aver normalizzato due vettori in modo da avere una lunghezza unitaria (pari a 1) il dot product esprimerà il coseno dell'angolo compreso fra loro.

1.4.4. Matrix - Vector Products

Adesso possiamo vedere il prodotto fra una matrice $m \times n$ $\mathbf{A}$ e un vettore n -dimensionale $\mathbf{x}$. Per prima cosa visualizziamo la matrice come vettori riga:

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_m^\top \end{bmatrix}$$

Dove ogni $\mathbf{a}_i^\top \in \mathbb{R}^n$ é un vettore-riga che rappresenta la i -esima riga di $\mathbf{A}$.

Il prodotto matrice-vettore $\mathbf{Ax}$ é semplicemente un vettore colonna di lunghezza m dove l'elemento i é il dot product $\mathbf{a}_i^\top \mathbf{x}$:

$$\mathbf{Ax} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_m^\top \end{bmatrix} \mathbf{x} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{x} \\ \mathbf{a}_2^\top \mathbf{x} \\ \vdots \\ \mathbf{a}_m^\top \mathbf{x} \end{bmatrix}$$

Possiamo vedere quindi la moltiplicazione con una matrice $\mathbf{A} \in \mathbb{R}^{m \times n}$ come una trasformazione che porta i vettori da $\mathbb{R}^n$ a $\mathbb{R}^m$. Queste trasformazioni sono molto utili infatti sono l'operazione principale usata in ogni layer dove, dato l'output del layer precedente, viene calcolato l'output attuale.

Per rappresentare questi prodotti nel codice usiamo la funzione `mv`. Per effettuarla é importante che la dimensione di $\mathbf{A}$ sia la stessa di $\mathbf{x}$. In Python inoltre abbiamo un operatore pensato sia per prodotti matrix-matrix che matrix-vector che é `@`:

```
A.shape, x.shape, torch.mv(A, x), A@x

# Output
# (torch.Size([2, 3]), torch.Size([3]), tensor([ 5., 14.]), tensor([ 5., 14.]))
```

1.4.5. Matrix - Matrix Multiplication

Il concetto é molto simile a quello dei dot product. Prendiamo due matrici $\mathbf{A} \in \mathbb{R}^{n \times k}$ e $\mathbf{B} \in \mathbb{R}^{k \times m}$:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1k} \\ a_{21} & a_{22} & \dots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nk} \end{bmatrix}, \mathbf{B} = \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1m} \\ b_{21} & b_{22} & \dots & b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \dots & a_{km} \end{bmatrix}$$

Sia $\mathbf{a}_i^\top \in \mathbb{R}^k$ il vettore-riga che rappresenta la i -esima riga della matrice $\mathbf{A}$ e sia $\mathbf{b}_j \in \mathbb{R}^k$ il vettore-colonna che rappresenta la j -esima colonna della matrice $\mathbf{B}$:

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix}, \mathbf{B} = [\mathbf{b}_1 \ \mathbf{b}_2 \ \dots \ \mathbf{b}_m]$$

Per formare la matrice $\mathbf{C} \in \mathbb{R}^{n \times m}$ calcoliamo ogni elemento c_{ij} come il dot product tra la i -esima riga di $\mathbf{A}$ e la j -esima colonna di $\mathbf{B}$:

$$C = AB = \begin{bmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \\ \vdots \\ \mathbf{a}_n^\top \end{bmatrix} [\mathbf{b}_1 \ \mathbf{b}_2 \ \dots \ \mathbf{b}_m] = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{b}_1 & \mathbf{a}_1^\top \mathbf{b}_2 & \dots & \mathbf{a}_1^\top \mathbf{b}_m \\ \mathbf{a}_2^\top \mathbf{b}_1 & \mathbf{a}_2^\top \mathbf{b}_2 & \dots & \mathbf{a}_2^\top \mathbf{b}_m \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^\top \mathbf{b}_1 & \mathbf{a}_n^\top \mathbf{b}_2 & \dots & \mathbf{a}_n^\top \mathbf{b}_m \end{bmatrix}$$

Possiamo pensare ad una moltiplicazione matrix-matrix AB equivalente ad effettuare m prodotti matrix-vector o $m \times n$ dot products per mettere insieme i risultati e ottenere una matrice $n \times m$.

1.5. Norms

Di base la *norm* di un vettore ci dice «quanto é grande». Ne esistono diverse, ad esempio la l_2 misura la lunghezza Euclidea di un vettore.

La norm é una funzione $\|\cdot\|$ che mappa un vettore in uno scalare e soddisfa le 3 seguenti proprietà:

1. Dato un array $\mathbf{x}$, se scaliamo tutti i suoi elementi per uno scalare $a \in \mathbb{R}$ anche la norm scala:

$$\|a\mathbf{x}\| = |a| \|\mathbf{x}\|$$

2. Dati due vettori $\mathbf{x}$ e $\mathbf{y}$, la norm soddisfa la *triangle inequality*:

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$$

3. La norm di un vettore é non-negativa e si annulla soltanto se il vettore é zero:

$$\|\mathbf{x}\| > 0 \text{ for all } \mathbf{x} \neq 0$$

Esistono diverse funzioni valide come norms e diverse norms rappresentano diversi concetti di grandezza. La norm Euclidea corrisponde alla radice quadrata della somma dei quadrati di un vettore, questa é chiamata norm l_2 e possiamo esprimerla come:

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

Nel codice possiamo chiamare semplicemente il metodo `norm`:

```
u = torch.tensor([3.0, -4.0])
torch.norm(u)

# Output
# tensor(5.)
```

Un'altra norm comune é la l_1 anche chiamata *Manhattan distance*, questa somma i valori assoluti degli elementi del vettore:

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

Questa, rispetto alla l_2 , é meno sensibile ai valori anomali, per calcolarla combiniamo i metodi per il valore assoluto e la somma:

```
torch.abs(u).sum()

# Output
# tensor(7.)
```

Sia la l_2 che la l_1 sono dei casi speciali della norm generica l_p :

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

Per quanto riguarda le matrici però le cose si fanno più complicate. Possiamo vedere le matrici sia come insiemi di singoli elementi sia come oggetti che agiscono su vettori trasformandoli in altri vettori. Possiamo chiederci ad esempio quanto il prodotto matrice-vettore $\mathbf{X}\mathbf{v}$ può essere lungo rispetto al vettore $\mathbf{v}$, questo ci porta alla *spectral norm*. Però vediamo la *Frobenius norm* che è più semplice da calcolare ed è definita come la radice quadrata della somma dei quadrati degli elementi della matrice:

$$\|\mathbf{X}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n x_{ij}^2}$$

Questa si comporta come se fosse una norma l_2 di un vettore a forma di matrice.

Nel deep learning spesso cerchiamo di risolvere problemi di ottimizzazione, massimizzare la probabilità assegnata ai dati osservati, massimizzare il guadagno associato ad un modello di raccomandazione, minimizzare la distanza tra le rappresentazioni delle foto della stessa persona. Queste distanze sono spesso espresse come norme.

2. Calculus

2.1. Derivatives and Differentiation

Molto semplicemente, la derivata é il tasso di variazione di una funzione rispetto alle variazioni dei suoi argomenti. Le derivate ci dicono quanto velocemente una *loss function* cresce o decresce quando incrementiamo o decrementiamo ciascun parametro. Formalmente per delle funzione $f : \mathbb{R} \rightarrow \mathbb{R}$ che mappano scalari in altri scalari, la derivata di f nel punto x é definita come:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

Quando $f'(x)$ esiste, f si dice *differenziabile* in x e quando $f'(x)$ esiste per ogni x in un range di valori, come ad esempio $[a, b]$, diciamo che f é differenziabile su questo set. Non tutte le funzioni sono differenziabili comprese alcune che vorremmo ottimizzare. Tuttavia dato che il calcolo della derivata é fondamentale in quasi tutti gli algoritmi di addestramento, spesso ottimizziamo un surrogato differenziabile.

Possiamo interpretare la derivata $f'(x)$ come il *tasso di variazione istantaneo* di $f(x)$ rispetto ad x . Facciamo degli esempi, definiamo una funzione $u = f(x) = 3x^2 - 4x$:

```
def f(x):  
    return 3 * x ** 2 - 4 * x
```

Impostando $x = 1$ notiamo che $\frac{f(x+h)-f(x)}{h}$ si avvicina a 2 quando h si avvicina a 0. Non abbiamo una dimostrazione matematica rigorosa ma possiamo facilmente notare che $f'(1) = 2$:

```
for h in 10.0*np.arange(-1, -6, -1):  
    print(f'h={h:.5f}, numerical limit={{f(1+h)-f(1)}/h:.5f}')
```

Output
h=0.10000, numerical limit=2.30000
h=0.01000, numerical limit=2.03000
h=0.00100, numerical limit=2.00300
h=0.00010, numerical limit=2.00030
h=0.00001, numerical limit=2.00003

Esistono tantissime notazioni per indicare la derivata di una funzione. Data $y = f(x)$ tutte le seguenti espressioni sono equivalenti:

$$f'(x) = y' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx}f(x) = Df(x) = D_x f(x)$$

I simboli $\frac{d}{dx}$ e D sono *differentiation operators*. Vediamo inoltre alcune derivate di funzioni note:

$$\frac{d}{dx}C = 0 \text{ per ogni costante } C$$

$$\frac{d}{dx}x^n = nx^{n-1} \text{ per } n \neq 0$$

$$\frac{d}{dx}e^x = e^x$$

$$\frac{d}{dx}\ln x = x^{-1}$$

Funzioni composte da funzioni differenziabili sono anch'esse differenziabili. La seguente regola é utile quando lavoriamo con composizioni di qualsiasi funzioni differenziabili f e g e una costante C .

$$\begin{aligned}\frac{d}{dx}[Cf(x)] &= C \frac{d}{dx}f(x) \\ \frac{d}{dx}[f(x) + g(x)] &= \frac{d}{dx}f(x) + \frac{d}{dx}g(x) \\ \frac{d}{dx}[f(x)g(x)] &= f(x) \frac{d}{dx}g(x) + g(x) \frac{d}{dx}f(x) \\ \frac{d}{dx} \frac{f(x)}{g(x)} &= \frac{g(x) \frac{d}{dx}f(x) - f(x) \frac{d}{dx}g(x)}{g^2(x)}\end{aligned}$$

In questo modo possiamo facilmente calcolare la derivata della funzione precedente $3x^2 - 4x$:

$$\frac{d}{dx}[3x^2 - 4x] = 3 \frac{d}{dx}x^2 - 4 \frac{d}{dx}x = 6x - 4$$

Infatti impostando $x = 1$ otteniamo come risultato 2. Da notare che la derivata di una funzione ci indica la sua *pendenza* in un punto.

2.2. Partial Derivatives and Gradients

Per adesso abbiamo calcolato la derivata di funzioni con una sola variabile ma nel deep learning dovremo lavorare con funzioni che hanno diverse variabili. Definiamo $y = f(x_1, x_2, \dots, x_n)$ una funzione con n variabili, la *partial derivative* di y rispetto al suo i -esimo parametro x_i é:

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}$$

Per calcolarlo possiamo trattare tutti gli altri parametri come costanti e calcolare la derivata di y rispetto ad x_i . Tutte le seguenti notazioni sono equivalenti:

$$\frac{\partial y}{\partial x_i} = \frac{\partial f}{\partial x_i} = \partial_{x_i} f = \partial_i f = f_{x_i} = f_i = D_i f = D_{x_i} f$$

Possiamo concatenare derivate parziali di una funzione a piú variabili, ognuna rispetto ad una variabile, e ottenere un vettore che chiamiamo **gradiente** della funzione. Supponiamo di avere come input di una funzione $f: \mathbb{R}^n \rightarrow \mathbb{R}$ un vettore n -dimensionale $\mathbf{x} = [x_1, x_2, \dots, x_n]^\top$ e l'output uno scalare. Il gradiente della funzione f rispetto ad $\mathbf{x}$ é un vettore di n derivate parziali:

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = [\partial_{x_1} f(\mathbf{x}), \partial_{x_2} f(\mathbf{x}), \dots, \partial_{x_n} f(\mathbf{x})]^\top$$

Quando il nome delle variabili non crea ambiguitá, possiamo sostituire $\nabla_{\mathbf{x}} f(\mathbf{x})$ con $\nabla f(\mathbf{x})$. Inoltre ci sono le seguenti proprietà:

- $\forall \mathbf{A} \in \mathbb{R}^{m \times n}$ si ha che $\nabla_{\mathbf{x}} \mathbf{A} \mathbf{x} = \mathbf{A}^\top$ e $\nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} = \mathbf{A}$. É l'equivalente della derivata di base, infatti se abbiamo la variabile che moltiplica una costante e deriviamo per quella variabile, possiamo rimuoverla.
- Per matrici quadrate $\mathbf{A} \in \mathbb{R}^{n \times n}$ si ha che $\nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$ e in particolare $\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = \nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{x} = 2\mathbf{x}$

In modo analogo, per ogni matrice $\mathbf{X}$ si ha che $\nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}$

2.3. Chain Rule

Nel deep learning calcolare i gradienti non é semplice dato che spesso si ha a che fare con complesse funzioni innestate. In questi casi si utilizza la *chain rule*. Torniamo per un attimo a funzioni con una sola variabile e supponiamo $y = f(g(x))$ dove $y = f(u)$ e $u = g(x)$ sono entrambe differenziabili. La chain rule ci dice che

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$$

Prendendo quindi una funzione con piú variabili, supponiamo $y = f(\mathbf{u})$ abbia le variabili $u_1, u_2, \dots, u_m$ dove ogni $u_i = g_i(\mathbf{x})$ ha variabili $x_1, x_2, \dots, x_n$ e quindi $\mathbf{u} = g(\mathbf{x})$. Allora la chain rule ci dice che:

$$\frac{\partial y}{\partial x_i} = \frac{\partial y}{\partial u_1} \frac{\partial u_1}{\partial x_i} + \frac{\partial y}{\partial u_2} \frac{\partial u_2}{\partial x_i} + \dots + \frac{\partial y}{\partial u_m} \frac{\partial u_m}{\partial x_i} \text{ e quindi } \nabla_{\mathbf{x}} y = \mathbf{A} \nabla_{\mathbf{u}} y$$

Dove $\mathbf{A} \in \mathbb{R}^{n \times m}$ é una matrice che contiene le derivate del vettore $\mathbf{u}$ rispetto al vettore $\mathbf{x}$. Quindi calcolare il gradiente si può ridurre a calcolare un prodotto vettore-matrice.

3. Automatic Differentiation

Fortunatamente non dobbiamo calcolare noi i gradienti a mano, ormai tutti i più recenti framework di deep learning implementano l'*automatic differentiation* (o *autograd*), ogni volta che i dati passano fra le funzioni il framework costruisce un *computational graph* che traccia le dipendenze fra i valori. Per calcolare le derivate, l'automatic differentiation cammina questo grafo al contrario applicando la chain rule, l'algoritmo che la applica è chiamato *backpropagation*.

Prendiamo come esempio la funzione $y = 2\mathbf{x}^\top \mathbf{x}$ dove appunto $\mathbf{x}$ è un vettore colonna. Iniziamo assegnando ad x un valore iniziale:

```
x = torch.arange(4.0)
x

# Output
# tensor([0., 1., 2., 3.]
```

Però prima di poter calcolare il gradiente di y rispetto ad $\mathbf{x}$ ci serve un posto dove memorizzarlo. Vogliamo inoltre evitare di allocare sempre nuova memoria dato che la derivata va calcolata tantissime volte per un singolo valore. Per farlo utilizziamo:

```
x.requires_grad_(True)
x.grad # Come valore default ha None
```

Adesso possiamo calcolare la nostra funzione e assegnare il risultato ad y :

```
y = 2 * torch.dot(x, x)
y

# Output
# tensor(28., grad_fn=<MulBackward0>)
```

Adesso possiamo calcolare il gradiente di y rispetto ad x chiamando il metodo *backward* per poi accedere all'attributo *grad*:

```
y.backward()
x.grad

# Output
# tensor([ 0.,  4.,  8., 12.]
```

Adesso calcoliamo un'altra funzione di x e il suo gradiente, da notare che PyTorch non pulisce il buffer del gradiente quando ne deve registrare un altro, quello nuovo viene aggiunto al vecchio valore, questo comportamento è utile quando vogliamo ottimizzare funzioni, per resettare il valore però basta chiamare il metodo `x.grad.zero_()`:

```
x.grad.zero_()
y = x.sum()
y.backward()
x.grad

# Output
# tensor([1., 1., 1., 1.]
```

3.1. Backward for Non-Scalar Variables

Quando y è un vettore allora la rappresentazione della derivata di y rispetto ad un altro vettore x è una matrice chiamata *Jacobian* che contiene le derivate parziali di ogni componente di y rispetto ad ogni componente di x , ovviamente per y e x di ordini superiori avremo un tensor di ordine ancora più grande.

Mentre la Jacobiana è utile in tecniche di machine learning più avanzate, nella maggior parte dei casi non ci serve costruirla tutta ma ci interessa ottenere un vettore di gradienti che abbia la stessa forma e dimensione del vettore x . Durante l'addestramento infatti avremo che x rappresenta i pesi della rete e riceviamo in input un batch di dati, la loss function calcolerà su y gli errori per ogni batch, a questo punto non ci interessa calcolare il gradiente per ogni componente rispetto ad ogni altro componente, ovvero come ogni peso si è comportato in ogni foto, o meglio lo calcoliamo ma non ci serve memorizzarlo possiamo sommare tutti i gradienti e capire come quel peso si è comportato in generale in quel batch di dati.

3.2. Detaching Computation

In alcuni casi vogliamo evitare di tracciare il computationl graph per alcuni calcoli. Supponiamo di avere $z = x * y$ e $y = x * x$ ma vogliamo concentrarci sull'influenza *diretta* di x su z invece che passare per y . Per farlo possiamo creare una nuova variabile u che assume lo stesso valore di y ma di cui cancelliamo la «provenienza».

```
x.grad.zero_()
y = x * x
u = y.detach()
z = u * x

z.sum().backward()
x.grad == u

# Output
# tensor([True, True, True, True])
```

Otteniamo che il gradiente è uguale u appunto perchè non sappiamo da cosa deriva e viene quindi trattato come costante, se avessimo saputo che $u = x * x$ allora la derivata di x^3 sarebbe stata $3x^2$.

Possiamo comunque calcolare i gradienti di y dato che è u la variabile scollegata:

```
x.grad.zero_()
y.sum().backward()
x.grad == 2 * x

# Output
# tensor([True, True, True, True])
```

4. Linear Neural Networks for Regression

I problemi di *regression* sono quei problemi dove vogliamo fare una previsione di un valore numerico come ad esempio un prezzo. Come esempio prendiamo appunto quello di voler stimare il prezzo di una casa in base alla sua dimensione ed età. Per sviluppare un modello in grado di fare questo abbiamo bisogno di dati, un machine learning il dataset prende il nome di *training set* dove ogni riga si chiama *example* e quello che vogliamo indovinare *label*. Le variabili su cui si basa la previsione prendono il nome di *features*.

4.1. Basics

La *Linear Regression* è uno dei problemi più semplici e popolari nei problemi di regression. La prima assunzione che si fa è che la relazione fra le feature $\mathbf{x}$ e la label y sia principalmente lineare, ovvero che il valore atteso $E[Y \mid X = \mathbf{x}]$ può essere espresso come una somma pesata delle features $\mathbf{x}$. Indichiamo con n il numero di examples del nostro dataset, ed usiamo indici in alto per indicare il numero di example o label e indici in basso per numerare le feature di un example. Quindi $\mathbf{x}^i$ indica l' i -esimo example e $x_j^{(i)}$ indica la sua j -esima feature.

4.2. Model

Con l'assunzione fatta prima sulla linearità abbiamo detto che il valore atteso del prezzo può essere espresso come somma pesata delle features:

$$\text{price} = w_{\text{area}} \cdot \text{area} + w_{\text{age}} \cdot \text{age} + b$$

Dove w_{area} e w_{age} sono chiamati *weights* e b *bias*. I pesi determinano l'influenza di ogni feature sulla nostra predizione, il bias determina il valore della predizione quando tutte le features sono a zero. Anche se non è praticamente possibile avere ad esempio una casa con area uguale a 0 abbiamo comunque bisogno di un bias che ci permette di esprimere tutte le funzioni lineari delle nostre features.

Dato un dataset quindi il nostro obiettivo è quello di scegliere i giusti pesi $\mathbf{w}$ e il bias b in modo che, in media, il modello faccia giuste predizioni.

In machine learning lavoreremo spesso con dataset di grandi dimensioni dove conviene utilizzare notazioni algebriche più compatte. Quando il nostro input consiste di d features assegnamo un index a ciascuna ed esprimiamo la nostra predizione $\hat{y}$ come:

$$\hat{y} = w_1 x_1 + \dots + w_d x_d + b$$

Raccogliendo tutte le features in un vettore $\mathbf{x} \in \mathbb{R}^d$ e tutti i pesi in un altro vettore $\mathbf{w} \in \mathbb{R}^d$ possiamo esprimere il modello in modo più compatto:

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b$$

In questo caso il vettore $\mathbf{x}$ corrisponde alle features di un singolo example. Spesso ci conviene fare riferimento alle features dell'intero dataset di n examples tramite la *design matrix* $\mathbf{X} \in \mathbb{R}^{n \times d}$, in quest'ultima ogni riga rappresenta un example e ogni colonna una feature. Per una collezione di features $\mathbf{X}$, la predizione $\hat{\mathbf{y}} \in \mathbb{R}^n$ può essere espressa tramite il prodotto matrice-vettore:

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b$$

Quindi date le features di un training set $\mathbf{X}$ e le corrispondenti labels $\mathbf{y}$, l'obiettivo della linear regression è quello di trovare un vettore di pesi $\mathbf{w}$ e il bias b in modo che, date

delle nuove feature in input, il modello riesca a predire la label con l'errore più basso possibile.

Ovviamente non è possibile che il nostro modello riesca a prevedere ogni valore, ci saranno dataset di n examples dove $y^{(i)}$ non vale esattamente $\mathbf{w}^\top \mathbf{x}^{(i)} + b$ per tutti gli examples. Una principale differenza potrebbe essere ad esempio lo strumento utilizzato per raccogliere i dati.

Adesso, prima di andare a cercare i migliori *parametri* $\mathbf{w}$ e b del modello ci servono ancora due cose:

- Una metrica per misurare la qualità del modello.
- Una procedura per aggiornare il modello e migliorarne la qualità.


4.3. Loss Function

La *Loss Function* quantifica la distanza tra il valore target reale e quello predetto dal modello. Tipicamente è un numero non-negativo dove i valori piccoli sono a nostro vantaggio e una loss pari a 0 indica una previsione perfetta. Per i problemi di regression la loss function più comune è la *squared error*. Quando la predizione per l'example i è $\hat{y}^{(i)}$ e la corrispondente label reale è $y^{(i)}$ allora la squared error è data:

$$l^{(i)}(\mathbf{w}, b) = \frac{1}{2}(\hat{y}^{(i)} - y^{(i)})^2$$

La divisione $\frac{1}{2}$ non fa realmente differenza ma è comoda dato che poi si va a cancellare quando viene calcolata la derivata.

Vediamo l'adattamento di un modello di linear regression su dati monodimensionali:



Da notare che le grandi differenze fra i valori stimati dal modello e quelli target comportano contributi ancora più grandi alla loss per via della sua forma quadratica, quest'ultima porta sì il modello a evitare errori enormi ma potrebbe anche comportare un'eccessiva sensibilità ai dati anomali.

Per misurare la qualità di un modello sul training set basta calcolare la media della loss su quest'ultimo:

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n l^{(i)}(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2}(\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})^2$$

Quando addestriamo un modello stiamo cercando i parametri $(\mathbf{w}^*, b^*)$ che minimizzano la loss totale in tutti gli examples di training:

$$\mathbf{w}^*, b^* = \underset{\mathbf{w}, b}{\operatorname{argmin}} L(\mathbf{w}, b)$$

4.4. Analytic Solution

Rispetto a molti altri problemi, la linear regression si può risolvere in modo molto semplice, possiamo infatti trovare i parametri ottimali applicando una semplice formula.

Per prima cosa possiamo includere il bias b nei pesi $\mathbf{w}$ aggiungendo una colonna di tutti 1 alla design matrix. A questo punto il nostro problema diventa quello di minimizzare la formula $\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2$, finché la design matrix $\mathbf{X}$ ha rango pieno e quindi nessuna feature è linearmente dipendente dalle altre ci sarà un solo punto critico nella loss e corrisponderà al minimo in tutto il dominio della funzione. Prendiamo quindi la derivata della loss rispetto a $\mathbf{w}$ e minimizziamo a 0:

$$\partial_{\mathbf{w}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 = 2\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) = 0 \text{ quindi } \mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \mathbf{X}\mathbf{w}$$

Risolvendo per $\mathbf{w}$ la soluzione per il nostro problema di ottimizzazione:

$$\mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Da notare che questa soluzione è unica quando la matrice $\mathbf{X}^\top \mathbf{X}$ è invertibile ovvero quando le colonne della design matrix sono linearmente indipendenti.

Inoltre una soluzione semplice come questa non dobbiamo aspettarcela per tutti i problemi che ci ritroveremo ad affrontare.

4.5. Minibatch Stochastic Gradient Descent

La miglior tecnica per ottimizzare i parametri di un modello consiste nel ridurre l'errore in step aggiornando i parametri in modo da diminuire sempre di più la loss function, questo algoritmo è chiamato *gradient descent*. L'applicazione più semplice è quella di calcolare la derivata della loss function che non è altro che la media della loss calcolata su ogni example del dataset, questo procedimento però può risultare estremamente lento dato che per ogni cambiamento dovremmo prima iterare sull'intero dataset.

Possiamo provare a considerare l'idea completamente opposta ovvero aggiornare i pesi ad ogni example, l'algoritmo che otteniamo, il *stochastic gradient descent (SGD)* può essere sì buono anche su grandi dataset ma ha dei lati negativi. Il primo, di calcolo, è che i processori sono molto più veloci a fare operazioni piuttosto che muovere dati nelle memorie, è molto più efficiente effettuare una moltiplicazione matrice-vettore piuttosto che tante moltiplicazioni vettore-vettore. Questo significa che è molto più lento processare un example alla volta rispetto a una batch completa. Un altro problema è che alcuni layer del modello, funzionano soltanto quando osserviamo più examples alla volta.

La soluzione sta nel mezzo, invece di prendere una batch intera o un solo example, prendiamo delle *minibatch*. La dimensione di questa dipende da diversi fattori come la quantità di memoria, i layers, la grandezza totale del dataset ecc... Di solito però una potenza di 2 compresa tra 32 e 256 è un buon inizio. Questo ci porta al *minibatch stochastic gradient descent*.

Nella sua forma più semplice, in ogni iterazione t , prendiamo una minibatch casuale $\mathcal{B}_t$ con $|\mathcal{B}|$ examples del training set. Calcoliamo poi la derivata della loss rispetto ai pesi del modello. Infine moltiplichiamo la derivata (gradiente) appena ottenuto per un valore positivo η prestabilito chiamato *learning rate* e sottraiamo il risultato dai parametri attuali. Possiamo esprimere l'aggiornamento in questo modo:

$$(\mathbf{w}, b) \leftarrow (\mathbf{w}, b) - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}_t} \partial_{\mathbf{w}, b} l^{(i)}(\mathbf{w}, b)$$

L'algoritmo esegue quindi:

1. Inizializza i valori dei parametri del modello, di solito in modo casuale.

2. Itera su minibatch casuali del dataset e aggiorna i parametri verso la direzione negativa del gradiente.

Dato che prendiamo una minibatch $\mathcal{B}$ dobbiamo normalizzare per la sua grandezza $|\mathcal{B}|$. Di solito la grandezza della minibatch e il learning-rate sono prestabili dall'utente, questi parametri che non vengono modificati durante il training si chiamano *hyperparameters*. Possono essere comunque ottimizzati attraverso diverse tecniche come la Bayesian optimization. Infine, la qualità del modello ottenuto viene misurata su un set di dati separato e mai visto dal modello chiamato *validation set*.

Dopo aver allenato il modello per un determinato numero di iterazioni, salviamo i parametri del modello che in questo caso denotiamo con $\hat{\mathbf{w}}, \hat{\mathbf{b}}$. Da notare che anche se la nostra funzione è completamente lineare, questi parametri non saranno gli esatti minimizzatori della loss function e non saranno nemmeno deterministici.

In generale il problema principale del deep learning non è trovare parametri ottimali per il dataset di training ma trovare dei parametri ottimali che forniscano buoni risultati su dati mai visti prima, questo è il problema della *generalizzazione*.

4.6. Predictions

Dato il modello $\hat{\mathbf{w}}^\top \mathbf{x} + \hat{\mathbf{b}}$ possiamo iniziare a fare previsioni su nuovi example. Nel deep learning di solito questa fase si chiama *inferenza* ma in realtà è un termine un po' improprio dato l'inferenza si riferisce a una qualsiasi conclusione raggiunta sulla base di prove, inclusi sia i valori dei parametri sia l'etichetta probabile per un'istanza non vista. Nella letteratura statistica l'inferenza fa riferimento all'inferenza dei parametri, per evitare confusione la chiameremo «previsione».

4.7. Vectorization for Speed

Quando addestriamo il modello vorremmo processare minibatches in modo simultaneo, per farlo abbiamo bisogno di vettorizzare i calcoli e sfruttare librerie di algebra lineare veloci invece di scrivere dei semplici loop in Python. Per vedere l'impatto di questo consideriamo due metodi per sommare vettori, per prima cosa inizializziamo due vettori da 10.000 elementi, come primo metodo facciamo un loop sui vettori.

```
n = 10000
a = torch.ones(n)
b = torch.ones(n)
```

Adesso possiamo verificare i tempi andando a fare la somma con il primo metodo:

```
c = torch.zeros(n)
t = time.time()
for i in range(n):
    c[i] = a[i] + b[i]
f'{time.time() - t:.5f} sec'

# Output
# '0.17802 sec'
```

Se invece utilizziamo l'operatore `+`:

```
t = time.time()
```




```
d = a + b
f'{time.time() - t:.5f} sec'

# Output
# '0.00036 sec'
```

Il secondo metodo è estremamente più veloce, questo infatti somma uno ad uno gli elementi in modo parallelo.

4.8. Linear Regression as a Neural Network

Le reti neurali sono abbastanza potenti da comprendere i modelli lineari e rappresentarli come reti dove ogni feature è rappresentata da un neurone di ingresso e sono tutti collegati in modo diretto all'output. Quindi:



Gli input sono $x_1, \dots, x_d$, ci riferiamo a d come numero di inputs oppure la dimensione delle features nel layer di input, l'output è o_1 ed è uno soltanto dato che stiamo provando a prevedere un solo valore. Dato che il neurone calcolato è soltanto uno e gli altri sono tutti dati possiamo pensare alla linear regression come una fully connected linear network.

5. Generalization

Per capire meglio questo concetto immaginiamo due studentesse che devono prepararsi per un esame, Ellie ha una memoria incredibile e riesce a ricordare praticamente ogni domanda di ogni esame passato ma questo significa che potrebbe comunque bloccarsi su una nuova domanda mai vista prima. Irene invece non riesce a ricordare nulla ma è bravissima a trovare schemi ricorrenti. Se l'esame consistesse veramente in solo domande riciclate allora Ellie supererebbe facilmente Irene, infatti anche se quest'ultima ottenesse un buonissimo 90% andrebbe comunque a perdere contro il 100% di Ellie, se però l'esame consistesse interamente in domande nuove allora Irene manterrebbe comunque il suo punteggio del 90% mentre Ellie fallirebbe completamente.

Il nostro obiettivo è quello di trovare dei pattern, ma come siamo sicuri di averne trovato uno invece di aver memorizzato tutti i dati di addestramento? Non abbiamo bisogno di prevedere i prezzi delle azioni di ieri o riconoscere malattie già diagnosticate, dobbiamo trovare pattern in situazioni mai viste prima. Questo problema della generalizzazione è il problema fondamentale del machine learning e di tutta la statistica.

Il fenomeno in cui l'adattamento risulta più vicino al training set che alla distribuzione sottostante è chiamato *overfitting* e le tecniche per contrastarlo sono chiamate *regularization methods*.

5.1. Training Error and Generalization Error

In un ambiente standard assumiamo che training set e test set siano presi in modo indipendente dalla stessa distribuzione, questa di solito viene chiamata *IID Assumption*. Da notare che senza questa assunzione non andremmo da nessuna parte, infatti per quale motivo dei dati presi da una distribuzione $P(X, Y)$ dovrebbero dirci come fare previsioni su dati generati da una diversa distribuzione $Q(X, Y)$? Per fare questi passaggi è necessario formulare ipotesi solide su come le due distribuzioni siano collegate. Prima però basiamoci sul caso in cui sono uguali ovvero nella IID.

Iniziamo distinguendo il *training error* R_{emp} che è calcolato sul training set e il *generalization error* R che invece è quello che ci aspettiamo dalla distribuzione. Possiamo vedere il generalization error come quello che vedremmo se applichiamo il nostro modello ad una sequenza infinita di dati presi dalla stessa distribuzione. Formalmente il training error è espresso come una somma:

$$R_{\text{emp}}[\mathbf{X}, \mathbf{y}, f] = \frac{1}{n} \sum_{i=1}^n l(\mathbf{x}^{(i)}, y^{(i)}, f(\mathbf{x}^{(i)}))$$

Mentre il generalization error è espresso come un integrale:

$$R[p, f] = E_{(\mathbf{x}, y) \sim P}[l(\mathbf{x}, y, f(\mathbf{x}))] = \int \int l(\mathbf{x}, y, f(\mathbf{x})) p(\mathbf{x}, y) d\mathbf{x} dy$$

Non possiamo mai calcolare esattamente il generalization error R , nessuno infatti ci dirà mai la forma precisa della funzione di densità $p(\mathbf{x}, y)$. Inoltre, non possiamo esaminare una sequenza infinita di dati. Nella pratica quindi dobbiamo fare una stima del generalization error applicando il nostro modello su un test set indipendente su una collezione di esempi $\mathbf{X}'$ e di labels $\mathbf{y}'$ che non sono presenti nel dataset.

5.2. Model Complexity

Di solito quando lavoriamo con tanti dati, il training e il generalization error tendono ad essere simili, quando però lavoriamo con modelli più complessi o con pochi examples ci aspettiamo che il training error scenda ma il generalization error sia abbastanza distante o che salga e questo non ci deve sorprendere. Immaginiamo un modello che, per ogni dataset di n esempi, riesce a trovare un set di parametri che si adattano perfettamente alle labels anche se assegnate in modo randomico, in questo caso anche se il modello si comporta benissimo nel training come possiamo capire qualcosa sul generalization error? Per quel che sappiamo il generalization error potrebbe anche essere peggiore di sparare a caso.

In generale, in assenza di restrizioni sul modello, basandoci soltanto su come il modello si è adattato al training set non possiamo concludere che abbia trovato un pattern generalizzabile.

Quando un modello è in grado di riconoscere delle labels, un basso training error non implica obbligatoriamente anche un basso generalization error ma nemmeno un alto generalization error. Le reti neurali profonde non ci permettono di trarre conclusioni basandoci esclusivamente sull'errore di addestramento, in questi casi dobbiamo fare maggiore affidamento sull'errore di validazioni ovvero quello calcolato su altri examples rispetto al training.

5.3. Underfitting or Overfitting

Quando compariamo training e validation error dobbiamo stare attenti a due situazioni particolari. Per prima cosa vogliamo vedere se i due errori sono abbastanza grandi ma c'è una leggera differenza fra i due. Se il nostro modello non riesce a ridurre il training error allora il modello è troppo semplice per riuscire a individuare un pattern, inoltre, dato che il gap tra training e generalization error è piccolo significa che possiamo usare un modello più complesso per ottenere risultati migliori. Questo fenomeno prende il nome di **underfitting**.

Per seconda cosa vogliamo controllare se il training error è decisamente inferiore del validation error, questo indica **overfitting**. Da notare che l'overfitting non è sempre una brutta cosa. Soprattutto nel deep learning, i migliori modelli ottengono spesso risultati superiori nel training rispetto alla validazione. Il nostro obiettivo finale è solamente che l'errore di generalizzazione sia basso, se poi c'è un gap con l'errore di addestramento non ci interessa, a meno che questo gap non sia talmente alto da non permettere una discesa dell'errore di validazione. Da notare che se l'errore di addestramento è zero allora il gap di generalizzazione è esattamente uguale all'errore di generalizzazione e quindi l'unico modo per ridurlo è ridurre il gap attraverso tecniche specifiche.

5.4. Model Selection

Di solito scegliamo il nostro modello finale soltanto dopo aver valutato diversi modelli, questo passo è chiamato appunto *model selection*.

Non dovremmo toccare il nostro set di test finché non abbiamo scelto gli hyperparameters, infatti se dovessimo usare il test set durante la scelta del modello rischiamo di andare in overfitting. Infatti andare in overfitting nel training non è un problema dato

che abbiamo poi la valutazione che ci garantisce affidabilità, ma se overfittiamo i dati di test non ce ne accorgeremmo.

Non dobbiamo quindi mai basarci sui dati di test per la scelta del modello, ma non possiamo nemmeno affidarci soltanto a quelli di training perché non siamo in grado di stimare l'errore di generalizzazione su questi. Nelle applicazioni pratiche la questione è ancora più confusa, infatti dovremmo utilizzare i dati di test una sola volta per valutare il modello migliore o per confrontare un numero limitato di modelli ma nella realtà i dati di test raramente vengono scartati dopo un solo utilizzo.

La prassi è quella di dividere il dataset in tre parti, includendo un set di validazione oltre al set di addestramento e di test. Il risultato è che la differenza tra set test e validation è molto ambigua, per questo spesso si utilizza soltanto training e validation.

5.5. Cross-Validation

Quando i dati per l'addestramento sono pochi non siamo in grado di separare abbastanza dati per creare un buon validation set. Una soluzione comune è il K – fold cross-validation dove il training set viene diviso in K sottoinsiemi con nessun elemento in comune, poi l'addestramento e la valutazione vengono effettuati K volte, ogni volta addestrando su $K - 1$ sottoinsiemi di training e valutando su l'ultimo sottoinsieme che viene preso come validation. Infine, l'errore di training e validation sono stimati facendo la media dei K risultati.

6. Weight Decay

Dato che abbiamo introdotto il problema dell'overfitting, possiamo introdurre la prima *regularization technique*. Ricordiamo però che possiamo sempre ridurre l'overfitting aggiungendo più dati di addestramento ma ovviamente potrebbe richiedere tanto tempo o spesa oppure potrebbe essere impossibile in determinati casi. Assumiamo quindi di avere già abbastanza dati e di qualità.

Una prima tecnica è quella di limitare il numero di feature, tuttavia limitarsi a scartare feature è un metodo troppo grossolano.

6.1. Norms and Weight Decay

Invece di manipolare il numero di parametri, il weight decay si basa sul restringere i valori che i parametri possono prendere. Viene anche chiamata l_2 regularization fuori dal mondo del deep learning. La tecnica si basa sul fatto che fra tutte le funzioni f , la funzione $f = 0$ è la più semplice, possiamo quindi misurare la complessità di una funzione in base alla distanza dei suoi parametri da zero. Ma quanto precisi dobbiamo essere mentre misuriamo questa distanza? Non c'è una risposta giusta.

Una semplice interpretazione potrebbe essere quella di misurare la complessità di una funzione lineare $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$ con qualche norma dei suoi pesi, ad esempio $\|\mathbf{w}\|^2$. Il metodo più comune per garantire che il vettore dei pesi sia di piccole dimensioni consiste nell'aggiungere la sua norma come termine di penalizzazione al problema di minimizzazione della loss. Il nostro obiettivo quindi non è più quello di minimizzare la prediction loss sulle training labels ma minimizzare la somma della prediction loss e il penalty term. A questo punto se il vettore dei pesi cresce troppo, l'algoritmo di apprendimento potrebbe concentrarsi sul minimizzare la norma dei pesi piuttosto che minimizzare l'errore di training e questo è esattamente quello che vogliamo. Significa infatti che l'algoritmo si trova costretto a fare un compromesso:

- Se tenta di abbassare troppo l'errore nel training ingrandendo i pesi allora la norma diventa alta.
- L'algoritmo allora preferirà accettare un errore di training leggermente più alto pur di mantenere i pesi piccoli e contenuti. La loss originariamente l'avevamo espressa come:

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})^2$$

Dove ricordiamo che: $\mathbf{x}^{(i)}$ sono le features, $y^{(i)}$ sono le label di ogni example i e $(\mathbf{w}, b)$ sono i pesi e il bias. Per penalizzare il vettore dei pesi dobbiamo aggiungere $\|\mathbf{w}\|^2$ alla loss, ma come fa il modello a bilanciare la loss standard con questa nuova penalità? Lo facciamo tramite la *regularization constant* λ , un hyperparameter non negativo il cui valore ottimale viene scelto valutando le prestazioni sul set di validazione. La nuova funzione diventa quindi:

$$L(\mathbf{w}, b) + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

In questo modo otteniamo:

- Se $\lambda = 0$ la penale si azzerà e si torna alla funzione di loss originale.

- Se $\lambda > 0$ stiamo imponendo un vincolo che forza la magnitudo di $\|\mathbf{w}\|$ a rimanere contenuta, più grande è λ e più severa sarà la penalità per pesi grandi. Si eleva al quadrato sempre per semplicità algebrica per il calcolo delle derivate.

Perché si sceglie la norma l_2 , e non ad esempio la l_1 ? Differenze comportamentali:

- La norma l_2 eleva al quadrato ogni singolo peso w_j , di conseguenza assegna una penalità sproporzionalmente alta ai pesi di grande valore. In questo modo spinge l'algoritmo ad evitare singoli pesi giganti e a distribuire il carico in modo uniforme. Inoltre rende il modello più robusto, se una singola variabile in input contiene rumore o un errore di misurazione, il suo impatto sul risultato sarà limitato perché il peso associato a questa è piccolo.
- La norma l_1 penalizza i pesi in modo proporzionale al loro valore assoluto senza accentuare i valori grandi. Questo porta i pesi ad azzerarsi completamente e il modello concentra tutta la sua capacità solo su un piccolo sottoinsieme di feature. Il vantaggio è che funziona come un meccanismo automatico di selezione delle variabili, se un peso diventa zero allora quella specifica feature non serve più per fare la predizione e questo permette di risparmiare memoria, calcolo e risorse nella fase di raccolta, archiviazione o trasmissione dei dati futuri.

La formula con minibatch stochastic gradient descent con regolarizzazione l_2 diventa quindi:

$$\mathbf{w} \leftarrow (1 - \eta\lambda)\mathbf{w} - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \mathbf{x}^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})$$

Notiamo che i termini dell'equazione sono:

- $(1 - \eta\lambda)\mathbf{w}$: sia η che λ sono numeri piccoli e positivi e quindi questo termine è un numero leggermente inferiore a 1, ad ogni passo di addestramento il peso viene prima «ristretto» ovvero moltiplicato per questo numero.
- Il resto è la classica correzione basata sull'errore commesso dal modello.

Si chiama weight decay perché se azzeriamo l'errore del modello sui dati allora l'aggiornamento dei pesi sarebbe soltanto

$$\mathbf{w} \leftarrow (1 - \eta\lambda)\mathbf{w}$$

E questo significa che i pesi decadrebbero esponenzialmente verso lo zero ad ogni iterazione.

Notiamo che per il bias b non viene fatta nessuna penalizzazione, questo perché sono i pesi che controllano la pendenza e la reattività delle singole variabili di input e causare quindi overfitting se troppo grandi, il bias invece sposta semplicemente la funzione in alto o in basso e non aggiunge oscillazioni al modello.

Infine notiamo che la l_2 regularization e il weight decay potrebbero non essere perfettamente equivalenti per altri algoritmi di ottimizzazione.

- Nella SGD aggiungere $\|\mathbf{w}\|^2$ alla loss o moltiplicare i pesi per $(1 - \eta\lambda)$ produce la stessa identica operazione matematica.
- Con ottimizzatori più complessi però questo non è vero, ad esempio con *Adam*. Infatti esistono varianti come *AdamW* che utilizzano anche il weight decay.

7. Linear Neural Network for Classification

7.1. Softmax Regression

In questa sezione ci concentriamo sui problemi di *classificazione* ovvero rispondere alla domanda *quale categoria?*

Nel mondo del machine learning la parola *classification* viene associata a due problemi distinti:

- Assegnare una singola categoria ad un elemento (hard assignment)
- Assegnare in percentuale tutte le categorie ad un elemento (soft assignment)

Questa distinzione non é molto chiara dato che spesso anche quando dobbiamo fare hard assignment vengono usati dei soft. Oppure ci sono casi dove piú categorie sono vere ad esempio un articolo di giornale che copre diversi temi, questo problema prende il nome di **multi-label classification**.

7.2. Classification

Iniziamo con una semplice image classification dove ogni input consiste in un'immagine 2×2 in scala di grigi. Possiamo rappresentare ogni pixel con un singolo scalare ottenendo quindi 4 features x_1, x_2, x_3, x_4 e assumiamo che queste immagini appartengano a 4 categorie «cat», «chicken», «dog».

Dobbiamo scegliere come rappresentare le labels e abbiamo due scelte. La piú naturale sarebbe scegliere $y \in \{1, 2, 3\}$ dove gli interi rappresentano $\{\text{dog}, \text{cat}, \text{chicken}\}$. Se le categorie avessero un ordine allora avrebbe senso ad esempio trasformare il problema in un *ordinal regression problem*. In generale però i problemi di classification non hanno le classi ordinate in base a qualcosa. C'è però un metodo per rappresentare queste classi, il *one-hot encoding* ovvero un vettore contenente tanti componenti quanti le categorie dove l'elemento corrispondente alla categoria é impostato a 1 e tutti gli altri a 0. Nel nostro esempio una label y sarà un vettore tridimensionale dove $(1, 0, 0)$ corrisponde a «cat», $(0, 1, 0)$ corrisponde a «chicken» e $(0, 0, 1)$ a «dog».

7.2.1. Linear Model


Per stimare la probabilità di ogni classe abbiamo bisogno di un modello con un numero di output pari al numeri di classi. Per affrontare la classificazione con modelli lineari avremo bisogno di tante funzioni affini quanti sono gli output, in realtà ne serve solo una in meno dato che la categoria finale deve essere la differenza tra 1 e la somma delle altre categorie. Ogni output corrisponde alla propria funzione affine. Nel nostro caso poiché abbiamo 4 features e 3 categorie in output, abbiamo bisogno di 12 scalari per rappresentare i pesi e di 3 scalari per rappresentare i bias, ottenendo:

$$o_1 = x_1 w_{11} + x_2 w_{12} + x_3 w_{13} + x_4 w_{14} + b_1$$

$$o_2 = x_1 w_{21} + x_2 w_{22} + x_3 w_{23} + x_4 w_{24} + b_2$$

$$o_3 = x_1 w_{31} + x_2 w_{32} + x_3 w_{33} + x_4 w_{34} + b_3$$

Il diagramma corrispondente sarà:



Utilizziamo infatti sempre un singolo layer e siccome il calcolo di ogni output dipende da ogni input, l'output layer può essere descritto come un *fully connected layer*. Per una notazione più concisa utilizziamo $\mathbf{o} = \mathbf{W}\mathbf{x} + \mathbf{b}$.

7.2.2. The Softmax

Supponendo di avere una funzione di loss adatta potremmo teoricamente tentare di minimizzare direttamente la differenza tra l'output del modello $\mathbf{o}$ e le labels $\mathbf{y}$, tuttavia trattare la classificazione come un normale problema di regressione presenta due limiti:

- Gli output o_i non garantiscono di sommare a 1
- Gli output o_i non sono necessariamente non negativi e non è detto che non superino il valore di 1.

Questi aspetti rendono il problema molto instabile e sensibile ai valori anomali (outliers). Ci possono essere appunto dei valori che facciano esplodere le probabilità oltre l'unità e per questo serve un meccanismo per «comprimere» gli output.

Per fare in modo che i valori siano non negativi e compresi tra 0 e 1 si utilizza una funzione esponenziale $P(y = i) \propto \exp(o_i)$. Questa rispetta il requisito per cui la probabilità aumenta all'aumentare di o_i , è monotona e produce solo valori non negativi. Per fare in modo che la somma di tutte le probabilità sia esattamente 1 si divide ciascun valore per la loro somma totale, questo processo è chiamato *normalizzazione*.

Unendo tutti questi passaggi si ottiene la formula della funzione **softmax**:

$$\hat{y}_i = \frac{\exp(o_i)}{\sum_j \exp(o_j)}$$

7.2.3. Vectorization

Per migliorare l'efficienza di calcolo, vettorizziamo i calcoli in minibatches. Assumiamo di avere una minibatch $\mathbf{X} \in \mathbb{R}^{n \times d}$ di n examples con dimensionalità d (numero di input) con infine q categorie di output. Allora abbiamo che $\mathbf{W} \in \mathbb{R}^{d \times q}$ e i bias $\mathbf{b} \in \mathbb{R}^{1 \times q}$.

$$\mathbf{O} = \mathbf{X}\mathbf{W} + \mathbf{b}$$

$$\hat{\mathbf{Y}} = \text{softmax}(\mathbf{O})$$

In questo modo l'operazione principale viene fatto tramite un prodotto matrice-matrice $\mathbf{X}\mathbf{W}$, inoltre siccome ogni riga $\mathbf{X}$ rappresenta un example l'operazione di softmax può essere calcolata *rowwise*: per ogni riga di $\mathbf{O}$ viene calcolata una funzione esponenziale e normalizzate con la somma.

7.3. Loss Function

Adesso che abbiamo una funzione che mappa le features $\mathbf{x}$ nelle probabilità $\hat{\mathbf{y}}$ ci serve un modo per ottimizzare l'accuracy di questo mapping. Ci affideremo alla stima della massima verosimiglianza.

7.3.1. Log-Likelihood

Il softmax restituisce un vettore $\hat{\mathbf{y}}$ che possiamo interpretare come probabilità condizionate per ogni classe dato un certo input $\mathbf{x}$, quindi $\hat{y}_1 = P(y = \text{cat} \mid \mathbf{x})$. Supponendo che le label $\mathbf{Y}$ siano rappresentate in formato *one-hot encoding* possiamo valutare quanto il nostro modello sia coerente con la realtà calcolando la probabilità complessiva di osservare tutte le etichette del dataset:

$$P(\mathbf{Y} \mid \mathbf{X}) = \prod_{i=1}^n P(y^{(i)} \mid \mathbf{x}^{(i)})$$

Questo prodotto si può fare assumendo che ogni esempio del dataset sia indipendente dagli altri. Massimizzare un prodotto di tantissimi numeri decimali piccolissimi è computazionalmente difficile e rischia di causare problemi di precisione numerica, per ovviare a questo problema si applica il logaritmo negativo e grazie alle proprietà dei logaritmi il prodotto si trasforma in una somma:

$$-\log P(\mathbf{Y} \mid \mathbf{X}) = \sum_{i=1}^n -\log P(y^{(i)} \mid \mathbf{x}^{(i)}) = \sum_{i=1}^n l(\mathbf{y}^{(i)}, \hat{\mathbf{y}})^{(i)}$$

L'obiettivo di massimizzare la verosimiglianza diventa così l'obiettivo equivalente di minimizzare la negative log-likelihood.

A questo punto la loss l diventa:

$$l(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_{j=1}^q y_j \log \hat{y}_j$$

Dato che il vettore delle labels $\mathbf{y}$ è in formato *one-hot* tutti i termini della sommatoria si annullano tranne quello corrispondente alla classe corretta, di conseguenza la loss si riduce semplicemente a prendere il logaritmo negativo della probabilità che il modello ha assegnato alla classe vera: $-\log \hat{y}_{\text{corretta}}$

7.3.2. Softmax and Cross-Entropy Loss

Sfruttando le proprietà dei logaritmi e il fatto che per un vettore one-hot la somma delle componenti è pari a 1, l'espressione iniziale si semplifica in:

$$l(\mathbf{y}, \hat{\mathbf{y}}) = \log \sum_{k=1}^q \exp(o_k) - \sum_{j=1}^q y_j o_j$$

Per capire come il modello impara, consideriamo la derivata della loss rispetto a un qualsiasi logit in input o_j :

$$\partial_{o_j} l(\mathbf{y}, \hat{\mathbf{y}}) = \frac{\exp(o_j)}{\sum_{k=1}^q \exp(o_k)} - y_j = \text{softmax}(\mathbf{o})_j - y_j$$

Notiamo che la derivata è semplicemente la differenza tra la probabilità stimata dal modello ($\hat{y}_j$) e l'etichetta reale (y_j). Il gradiente è esattamente uguale a quello riscontrato nella regressione lineare dove l'errore è dato dalla stima meno l'osservazione, questo rende il calcolo dei gradienti estremamente rapido e pulito.

7.4. Information Theory Basics

Spieghiamo alcuni termini della teoria dell'informazione utili per comprendere meglio alcuni concetti di deep learning.

7.4.1. Entropy

L'idea centrale della teoria dell'informazione é quantificare la quantità di informazione contenuta nei dati. Questo pone un limite alla nostra capacità di comprimere i dati. Per una distribuzione P , la sua entropia $H[P]$ é definita come:

$$H[P] = \sum_j -P(j) \log P(j)$$

Uno dei teoremi fondamentali della teoria dell'informazione afferma che per codificare dati estratti casualmente dalla distribuzione P abbiamo bisogno di almeno $H[P]$ «nats» per codificarli. Un nat é l'equivalente di un bit quando si utilizza un codice con base e anziché base 2, dunque un nat vale $\frac{1}{\log(2)} \approx 1.44$ bit. L'entropia misura quindi l'imprevedibilità o il «contenuto informativo» di una variabile casuale, se un evento é altamente prevedibile allora la sua entropia é bassa, se é molto incerto allora sarà alta.

7.4.2. Surprisal

Immaginiamo di avere un flusso di dati che vogliamo comprimere, se per noi é sempre facile prevedere il token successivo, allora questi dati sono facili da comprimere. Prendiamo l'esempio estremo in cui ogni token nel flusso assume sempre lo stesso valore. Questo é un flusso di dati molto noioso e soprattutto facile da prevedere. Poiché i token sono sempre gli stessi non dobbiamo trasmettere alcuna informazione per comunicare il contenuto del flusso.

Tuttavia se non riusciamo a prevedere perfettamente ogni evento, potremmo occasionalmente essere sorpresi. La sorpresa é maggiore quando a un evento viene assegnata una probabilità inferiore. Shannon ha stabilito che $\log \frac{1}{P(j)} = -\log P(j)$ serve a quantificare il grado di *surprisal* nell'osservare un evento j che ha una probabilità soggettiva $P(j)$. L'entropia definita prima é quindi la *sorpresa attesa* quando vengono assegnate le giuste probabilità che corrispondono realmente al processo di generazione dei dati.

7.4.3. Cross-Entropy Revisited

Se l'entropia é il livello di sorpresa provato da qualcuno che conosce la vera distribuzione di probabilità allora cos'è la *cross-entropy*? La cross-entropy da P a Q indicata con $H(P, Q)$ é la surprisal attesa da parte di un osservatore con probabilità soggettive Q quando osserva dati che sono stati generati secondo le probabilità P . Questa é data da:

$$H(P, Q) = \sum_j -P(j) \log Q(j)$$

La cross-entropy piú bassa possibile si ottiene quando $P = Q$, in questo caso la cross-entropy da P a Q é $H(P, P) = H(P)$.

Per capire meglio dobbiamo identificare i ruoli di P e Q :

- P é la realtà e rappresenta la vera distribuzione dei dati
- Q é il modello e rappresenta la probabilità soggettiva stimata dalla rete neurale.

Se la semplice entropia $H(P)$ misura la sorpresa di chi conosce perfettamente la verità, la cross-entropy $H(P, Q)$ misura quanto viene sorpreso un modello Q di fronte ai dati reali P :

- Se il modello Q é imperfetto e fa previsioni sballate, $H(P, Q)$ sarà molto alta.
- Man mano che il modello impara e si avvicina alla realtà, la sorpresa diminuisce.

- Il valore minimo assoluto si raggiunge quando il modello riflette perfettamente la realtà ($Q = P$) e in quel punto la cross-entropy diventa uguale all'entropia naturale dei dati.

8. Generalization in Classification

Finora ci siamo concentrati su come risolvere problemi di classificazione addestrando reti neurali lineari con diversi output e una funzione softmax. Interpretando gli output del nostro modello come previsioni probabilistiche abbiamo motivato e derivato la cross-entropy loss function che calcola la negative log likelihood che il nostro modello assegna alle labels. Ricordiamo che il nostro obiettivo rimane quello di imparare pattern generali da dati che non abbiamo mai visto prima, un'accuracy alta sul set di addestramento non significa nulla. Ogni volta che il nostro input è unico possiamo raggiungere un'accuratezza perfetta memorizzando il set di dati durante la prima epoca di addestramento e successivamente cercando l'etichetta ogni volta che vediamo una nuova immagine però, memorizzare le etichette degli esempi di addestramento non ci dice come classificare nuovi esempi, in assenza di ulteriori indicazioni potremmo dover ricorrere a ipotesi casuali ogni volta che incontriamo nuovi esempi.

Dobbiamo porci delle domande:

1. Quanti esempi di test ci servono per ottenere una buona stima dell'accuracy del nostro classificatore?
2. Cosa succede se continuiamo a valutare i modelli sullo stesso test set più volte?
3. Perché dovremmo aspettarci che l'adattamento del modello lineare al set di training dia risultati migliori rispetto al nostro schema di memorizzazione?

Scopriremo che la statistica ci garantisce per molti modelli che questi funzioneranno sui dati futuri prima ancora di addestrarli:

- ε è il massimo errore di differenza tollerato tra le prestazioni del modello sui dati di addestramento e le prestazioni nel mondo reale.
- n è la dimensione del dataset. La teoria afferma che fissato ε è possibile calcolare esattamente di quanti dati n abbiamo bisogno per garantire matematicamente che l'errore del modello rimanga entro quel margine, a prescindere da quale sia il dominio o la distribuzione dei dati.

Sfortunatamente però si scopre che sebbene questo tipo di garanzie sono molto limitate nella pratica del deep learning, perché servirebbe comunque un numero assurdo di esempi (triloni o più) anche quando riscontriamo che in molti compiti che ci interessano le reti neurali profonde generalizzano bene anche con molti meno esempi, nell'ordine delle migliaia.

Per questo si sviluppa reti neurali:

- Rinuncia alle garanzie matematiche iniziali.
- Utilizza architetture, iperparametri e tecniche di regolarizzazione che in passato hanno funzionato su problemi simili.
- La validità e capacità di generalizzazione del modello vengono provate solo dopo o durante l'addestramento misurando direttamente le prestazioni su un set di validazione o test nascosto.

8.1. The Test Set

Vogliamo capire quanto deve essere grande il test set per essere certi che l'errore misurato sia davvero affidabile.

Supponiamo di avere un classificatore f e un set di test $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^n$ mai visto durante l'addestramento. L'errore empirico $\varepsilon_{\mathcal{D}}(f)$ è la percentuale di errori commessa dal modello sul nostro dataset di test $\mathcal{D}$:

$$\varepsilon_{\mathcal{D}}(f) = \frac{1}{n} \sum_{i=1}^n 1(f(x^{(i)}) \neq y^{(i)})$$

Abbiamo poi l'errore di popolazione $\varepsilon(f)$ ovvero l'errore reale atteso se applicassimo il modello all'intera popolazione ideale di dati possibili $P(X, Y)$:

$$\varepsilon(f) = E_{(x,y) \sim P} 1(f(x) \neq y)$$

Siccome non possiamo misurare la popolazione intera usiamo l'errore empirico come stimatore statistico dell'errore reale.

Il teorema del limite centrale ci dice che la media campionaria converge verso il valore reale a una velocità proporzionale a $\mathcal{O}\left(\frac{1}{\sqrt{n}}\right)$, questo implica una regola fondamentale sulla dimensione del test set:

- Per raddoppiare la precisione sulla stima dell'errore dobbiamo moltiplicare per 4 la dimensione del test set.
- Per ridurre l'incertezza di un fattore 100 dobbiamo raccogliere 10.000 volte più dati di test.

Ma di quanti ne abbiamo bisogno nella pratica? Ogni singola predizione è una variabile di Bernoulli: vale 1 (errore) o 0 (corretto), la varianza di una distribuzione Bernoulli è $\sigma^2 = \epsilon(f)(1 - \epsilon(f))$ ed è massima quando la percentuale di errore è del 50% ($\epsilon = 0.5$) dove $\sigma^2 = 0.25$. Da questo valore possiamo calcolare la deviazione standard massima della stima dell'errore $\sqrt{\frac{0.25}{n}}$. Applicando la regola dell'intervallo di confidenza:

1. Margine di ± 0.01 : Servono circa 2.500 campioni
2. Confidenza al 95%: Per garantire che l'errore misurato sia entro ± 0.01 dall'errore reale con il 95% di confidenza risolviamo l'equazione $2 \cdot \sqrt{\frac{0.25}{n}} = 0.01$ ottenendo $n = 10.000$ campioni. Per questo in molti dataset famosi abbiamo appunto 10.000 campioni.

Il Teorema del Limite Centrale è un risultato asintotico ovvero vale per $n \rightarrow \infty$, per avere una garanzia matematica rigorosa valida anche su un numero finito di dati n si applica la **Disuguaglianza di Hoeffding**:

$$P(\epsilon_{\mathcal{D}}(f) - \epsilon(f) \geq t) < \exp(-2nt^2)$$

Impostando un margine $t = 0.01$ e chiedendo una confidenza del 95% la formula indica che servono circa 15.000 campioni.

8.2. Test Set Reuse

Immaginiamo di avere un modello f_1 , abbiamo usato il validation set per gli iperparametri e infine misurato l'errore reale su un test incontaminato. Successivamente scriviamo un nuovo modello f_2 con un diverso approccio, lo addestriamo e scegliamo i valori in base al validation set e vediamo che supera f_1 . Ora possiamo valutare f_2 sul test set ma *matematicamente parlando* non abbiamo più un test set valido.

Il primo problema è che quando valutiamo un singolo classificatore f la statistica garantisce un intervallo di confidenza al 95% il che significa che c'è solo un 5% di probabilità che il risultato sia dovuto al caso. Se però iniziamo a valutare k modelli differenti sullo stesso identico test set:

- La probabilità che almeno uno di questo ottenga un punteggio buono solo per pura fortuna cresce enormemente.
- Con 20 modelli valutati sullo stesso test set è quasi matematicamente certo che uno di essi mostrerà prestazioni sopravvalutate rispetto alla realtà.
- Questo fenomeno porta al problema della *false discovery*.

Il secondo problema è l'*Adaptive Overfitting* ovvero:

- Tutte le garanzie matematiche viste precedentemente si basano sull'assunzione fondamentale che il modello sia stato scelto senza alcun contatto da parte del test set.
- Quando selezioniamo il modello f_2 dopo aver visto le prestazioni di f_1 sul test set, l'informazione contenuta nel test set è indirettamente trapelata nella mente del ricercatore.
- Questo fenomeno si chiama *Adaptive Overfitting*, il test set ha perso la sua neutralità e cessa di essere una misura imparziale del mondo reale.

Come ci si difende? Ci sono dei consigli pratici da seguire come consultare il test set il meno frequentemente possibile. Più il dataset è piccolo più bisogna essere rigidi. Nelle competizioni o nei progetti reali la prassi migliore è declassare il vecchio test set a semplice set di validazione ed estrarre un test set completamente nuovo per la valutazione finale.

8.3. Statistical Learning Theory

Spesso i soli test set empirici ci lasciano insoddisfatti per due motivi:

- Raramente siamo i primi ad usare un test set quindi qualcuno ha già valutato i propri modelli su quel test set rendendolo di fatto parzialmente compromesso.
- Un test set ci dice soltanto a posteriori se un singolo modello ha funzionato ma non ci offre garanzie matematiche a priori sul perché un'intera classe di modelli dovrebbe funzionare.

Per colmare questo spazio nasce la **Statistical Learning Theory**, l'obiettivo principale è porre un limite superiore al divario di generalizzazione mettendo in relazione le proprietà strutturali del modello con il numero di dati disponibili n .

C'è una differenza fondamentale tra valutare un modello fisso e addestrarne uno. Il modello fisso f è facile da valutare su dati nuovi infatti l'errore sul test set è una stima non distorta dell'errore reale. Quando invece addestriamo un modello f_S stiamo scegliendo una specifica funzione f_S all'interno di uno spazio di funzioni possibili $\mathcal{F}$. Poiché i parametri di un modello sono continui, questo spazio contiene un numero infinito di modelli ($|\mathcal{F}| = \infty$). Quando valutiamo un'intera famiglia di modelli infiniti sui dati di addestramento $\mathcal{S}$ c'è un forte rischio di sceglierne uno che ottiene un valore di errore bassissimo sul training solo per puro caso e che poi si rivelerà un disastro nel mondo reale.

Affrontiamo ora il concetto di **Convergenza Uniforme**. Vogliamo dimostrare che con un'alta probabilità ($1 - \delta$), l'errore empirico di TUTTI i modelli presenti nella classe $\mathcal{F}$ converga simultaneamente al loro errore reale nel mondo reale, entro un piccolissimo margine α . Tuttavia questo principio fallisce se la classe dei modelli è «troppo flessibile». Ci sono macchine che memorizzano tutto il training set e otterranno un errore empirico pari a 0 ma sui dati reali nuovi avrà un errore altissimo.

- I modelli troppo flessibili (Alta Varianza) si adattano perfettamente al training set ma rischiano un gravissimo overfitting.

- I modelli troppo rigidi (Altro bias) generalizzano bene ma rischiano di non imparare nulla (underfitting).

La teoria dell'apprendimento cerca di misurare matematicamente dove si colloca un modello lungo questo spettro.

Utilizziamo la **Dimensione VC**, una misura formale della «complessità» o «flessibilità» di una classe di modelli. Questa è il numero massimo di punti dati che una classe di modelli può *shatterare* ovvero la capacità del modello di separare o etichettare quei puntini in qualsiasi modo arbitrario possibile. Ad esempio un modello lineare in d dimensioni ha una dimensione VC pari a $d + 1$. Nel piano $2D(d = 2)$ una retta può separare qualsiasi combinazione di etichette per 3 punti, ma non per 4 punti, quindi la dimensione VC di una retta in 2D è 3. Uno dei contributi fondamentali è un limite tra la differenza fra errore empirico ed errore reale come funzione della VC dimension e il numero di sample:

$$P\left(R[p, f] - R_{\text{emp}}[\mathbf{X}, \mathbf{Y}, f] < \alpha\right) \geq 1 - \delta \text{ for } \alpha \geq c \sqrt{\frac{\text{VC} - \log \delta}{n}}$$

Dove:

- $R[p, f]$ errore reale
- R_{emp} errore empirico sul dataset di addestramento
- α il margine massimo del divario di generalizzazione
- $1 - \delta$ la probabilità di confidenza
- n il numero di examples
- VC la dimensione VC del modello
- c una costante positiva dipendente dal tipo di loss

La formula dimostra che l'errore decade alla classica velocità $\mathcal{O}\left(\frac{1}{\sqrt{n}}\right)$ tuttavia la teoria VC risulta drammaticamente troppo pessimista per le reti neurali moderne. Le reti neurali profonde hanno una dimensione VC enormemente alta, se applicassimo rigorosamente la formula servirebbero trilioni di dati per spiegare la loro generalizzazione. Eppure, nella pratica le reti neurali riescono a generalizzare bene anche con molti meno dati, questo rimane uno dei grandi misteri e ancora aperti del deep learning moderno.

9. Environment and Distribution Shift


Fino ad ora abbiamo trattato i problemi di apprendimento assumendo che i dati di addestramento e i dati di test venissero estratti dalla stessa distribuzione di probabilità (IID). Tuttavia quando applichiamo i modelli nel mondo reale questa assunzione cade quasi sempre. I modelli vengono addestrati su dati passati per fare predizioni sul futuro oppure vengono sviluppati in un determinato ambiente e distribuiti in contesti completamente diversi. Comprendere come cambia l'ambiente e come la distribuzione dei dati si modifica nel tempo è fondamentale per progettare sistemi di machine learning robusti.

Formalmente indichiamo con X le variabili di input e con Y le variabili target. La distribuzione congiunta dei dati è espressa da $P(X, Y)$. Attraverso le regole della probabilità condizionata, possiamo scomporre $P(X, Y)$ in due modi equivalenti:

$$P(X, Y) = P(Y | X)P(X) = P(X|Y)P(Y)$$

Un **cambio di distribuzione** si verifica quando la distribuzione dei dati di addestramento $P_{\text{train}}(X, Y)$ differisce da quella di test $P_{\text{test}}(X, Y)$, esistono 3 casi principali:

Spostamento delle Covarianti - Si verifica quando la distribuzione delle feature in input $P(X)$ cambia tra addestramento e test ma la relazione condizionata $P(Y | X)$ rimane identica. Ad esempio un classificatore di gatti e cani addestrato esclusivamente su immagini reali che viene poi testato su disegni o vignette di cani e gatti, la forma e l'aspetto dell'input cambiano ma la definizione di cosa rende un animale un cane o un gatto rimane invariata.



Spostamento delle Etichette - Si verifica quando la distribuzione delle etichette cambia mentre la distribuzione condizionata degli input data l'etichetta $P(X|Y)$ rimane invariata. Questo presuppone una relazione causale in cui Y causa X . Ad esempio la diagnosi medica, durante un'epidemia dell'influenza la percentuale di popolazione malata $P(Y = \text{influenza})$ aumenta drammaticamente. Tuttavia, i sintomi presentati da un singolo individuo malato $P(X = \text{sintomi} | Y = \text{influenza})$ rimangono esattamente gli stessi.

Spostamento del concetto - Si verifica quando cambia direttamente la relazione funzionale tra gli input e le etichette, ovvero la distribuzione condizionata $P(Y|X)$ cambia nel tempo o nello spazio. Ad esempio l'analisi delle tendenze e dei prezzi. La definizione di un «prezzo ragionevole» per una casa o il significato di una parola nello slang cambiano profondamente nel corso dei decenni. Lo stesso input X porta a un'etichetta Y completamente diversa a seconda del momento storico.

9.0.1. Correction of Distribution Shift

... Moltiplichiamo la funzione di perdita di ciascun esempio di addestramento per un peso d'importanza.

Supponiamo di voler addestrare un modello di rilevamento di malattie respiratorie:

- Nel training set l'80% dei pazienti ha più di 70 anni e il 20% ha meno di 30 anni
- Nel test set ovvero la popolazione reale il 10% ha più di 70 anni e il 90% ha meno di 30 anni.

Se addestriamo il modello normalmente esso si concentrerà sugli anziani, per correggere questo Covariate Shift calcoliamo $\beta(x_{\text{giovane}}) = \frac{p_{\text{test}}}{p_{\text{train}}} = \frac{0.90}{0.20} = 4.5$ e calcoliamo anche $\beta(x_{\text{anziano}}) = \frac{0.10}{0.80} = 0.125$.

Quando la rete calcola l'errore durante l'addestramento, moltiplicherà la perdita sui dati dei giovani per 4.5 e quella degli anziani per 0.125. In questo modo obblighiamo la rete a dare priorità assoluta ad imparare bene sui campioni giovani, bilanciando l'errore esattamente per l'ambiente finale in cui lavorerà.

9.0.2. A Taxonomy of Learning Problems

Il modo in cui un modello interagisce con il proprio ambiente definisce la categoria del problema di machine learning.

- **Batch Learning:** Il modello viene addestrato su un dataset statico, congelato e poi distribuito senza ulteriori aggiornamenti.
- **Online Learning:** Il modello riceve continuamente dati in tempo reale, fa una predizione, osserva il risultato reale e aggiorna immediatamente i propri parametri.
- **Multi-Armed Bandits:** Il modello deve scegliere tra diverse azioni e riceve una ricompensa solo per l'azione scelta, dovendo bilanciare l'esplorazione e lo sfruttamento delle conoscenze.
- **Reinforcement Learning:** Il modello compie azioni in un ambiente dinamico, cambiando lo stato dell'ambiente stesso e ricevendo ricompense differite nel tempo.
- **Adversarial Learning:** L'ambiente contiene un oppositore attivo che modifica intenzionalmente l'input X per far fallire il modello.


10. Multilayer Perceptrons

Introduciamo la prima deep network. Quelle piú semplici sono appunto chiamate *multilayer perceptrons* e sono formate da piú strati di neuroni ciascuno dei quali é completamente connesso a quelli dello stato sottostante da cui riceve l'input e a quelli sovrastanti. Sebbene la differenziazione automatica semplifichi notevolmente l'implementazione degli algoritmi di deep learning, approfondiremo il modo in cui questi gradienti vengono calcolati nelle deep network. Esamineremo quindi l'inizializzazione dei parametri, la regolarizzazione e la generalizzazione per non incorrere in overfitting.

Precedentemente abbiamo visto modelli di regressione lineare e la softmax regression, sebbene siano molto semplici hanno una grande limitazione, assumono che la relazione tra le feature di input e il target finale sia strettamente lineare. Tuttavia il mondo reale non é lineare, per modellare pattern complessi abbiamo bisogno di classi di modelli piú flessibili: i **Multilayer Perceptrons (MLP)** che rappresentano l'architettura classica delle Neural Networks.

10.1. Hidden Layers

I MLP superano le limitazioni dei modelli lineari mediante l'inserimento di uno o piú *Hidden Layers* situati tra l'*Input Layer* e l'*Output Layer*. Se definiamo la matrice di input come $\mathbf{X} \in \mathbb{R}^{n \times d}$ dove n é il numero di examples e d il numero di feature, un hidden layer calcola una rappresentazione intermedia $\mathbf{H} \in \mathbb{R}^{n \times h}$ con h numero di neuroni nascosti.



$$\mathbf{H} = \mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}$$

L'output layer calcola poi il risultato finale $\mathbf{O} \in \mathbb{R}^{n \times q}$ con q uscite:

$$\mathbf{O} = \mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}$$

Dove $\mathbf{W}^{(1)} \in \mathbb{R}^{d \times h}$ e $\mathbf{W}^{(2)} \in \mathbb{R}^{h \times q}$ sono le matrici dei pesi mentre $\mathbf{b}^{(1)} \in \mathbb{R}^{1 \times h}$ e $\mathbf{b}^{(2)} \in \mathbb{R}^{1 \times q}$ sono i vettori di bias.

Se però ci limitassimo a concatenare queste trasformazioni lineari l'intero modello collasserebbe in una nuova singola trasformazione lineare:

$$\mathbf{O} = (\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})\mathbf{W}^{(2)} = \mathbf{X}\mathbf{W}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)} = \mathbf{X}\mathbf{W}' + \mathbf{b}'$$

Per evitare questo collasso e introdurre una reale capacità espressiva dobbiamo applicare elemento per elemento una *Activation Function* non lineare $\sigma(\cdot)$ agli output di ciascun hidden layer.

$$\mathbf{H} = \sigma(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})$$

$$\mathbf{O} = \mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}$$

Le Activation Functions decidono se e in che misura un neurone debba attivarsi, introducendo la non-linearità che é indispensabile nel deep learning. Le tre funzioni piú comunemente utilizzate sono:

- *ReLU (Rectified Linear Unit)*: É la scelta standard nel deep learning moderno grazie alla sua semplicità e velocità di calcolo.

$$\text{ReLU}(x) = \max(x, 0)$$

Ovvero annulla tutti i valori negativi e lascia inalterati quelli positivi.

- *Sigmoid*: La funzione sigmoid trasforma qualsiasi input reale in un valore compreso nell'intervallo aperto $(0, 1)$.

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}$$

- *Tanh (Hyperbolic Tangent)*: La funzione tanh trasforma l'input schiacciandolo nell'intervallo $(-1, 1)$:

$$\tanh(x) = \frac{1 - \exp(-2x)}{1 + \exp(-2x)}$$

Universal Approximation Theorem

Un Multilayer Perceptron dotato anche di un solo Hidden Layer contenente un numero sufficiente di neuroni e una Activation Function non lineare è in grado di approssimare con qualsiasi grado di precisione desiderato qualunque funzione continua.

Questo teorema garantisce che, indipendentemente da quanto sia complessa o contorta la relazione tra gli input e i target, esiste sempre una configurazione di pesi e bias in un MLP in grado di modellarla.

11. Forward Propagation, Backward Propagation, and Computational Graphs

Vogliamo capire a fondo come vengono ottimizzate le reti quando chiamiamo `loss.backward()`. Approfondiamo quindi i tre concetti chiave dell'addestramento: *Forward Propagation*, *Computational Graph*, *Backpropagation*.

11.1. Forward Propagation

La forward propagation si riferisce al calcolo e alla memorizzazione delle variabili intermedie per una Neural Network procedendo dall'Input Layer all'Output Layer. Consideriamo quindi un MLP a singolo Hidden Layer con norm L_2 (Weight Decay). Per semplicità assumiamo che non vi sia bias. Vediamo quindi in ordine i passaggi.

1. Dato un campione di input $\mathbf{x} \in \mathbb{R}^d$ il primo passaggio calcola l'input intermedio non attivato $\mathbf{z}$

$$\mathbf{z} = \mathbf{W}^{(1)}\mathbf{x}$$

Dove $\mathbf{W}^{(1)} \in \mathbb{R}^{h \times d}$ è la matrice dei pesi e h è il numero di unità nascoste.

2. Applicando la Activation Function ϕ elemento per elemento otteniamo il vettore delle attivazioni nascoste $\mathbf{h} \in \mathbb{R}^h$

$$\mathbf{h} = \phi(\mathbf{z})$$

3. L'attivazione $\mathbf{h}$ viene quindi moltiplicata per la matrice dei pesi del secondo strato $\mathbf{W}^{(2)} \in \mathbb{R}^{q \times h}$ per generare il vettore di output non normalizzato $\mathbf{o} \in \mathbb{R}^q$

$$\mathbf{o} = \mathbf{W}^{(2)}\mathbf{h}$$

4. Data l'etichetta target y calcoliamo la Loss Function L

$$L = l(\mathbf{o}, y)$$

5. In base alla regolarizzazione L_2 con iperparametro λ definiamo la penale s


$$s = \frac{\lambda}{2} (\|\mathbf{W}^{(1)}\|_F^2 + \|\mathbf{W}^{(2)}\|_F^2)$$

Dove $\|\cdot\|_F$ indica la norma di Frobenius della matrice. L'*Objective Loss* finale J da minimizzare è la somma tra la Loss del modello e la penale

$$J = L + s$$

11.2. Computational Graph of Forward Propagation

Tracciare un Computational Graph ci aiuta a visualizzare il flusso delle operazioni e la dipendenza tra operatori e variabili in una Neural Network.



I nodi rappresentano le variabili o le operazioni matematiche mentre gli archi indicano le dipendenze computazionali tra i valori.

11.3. Backpropagation

La Backpropagation si riferisce al metodo di calcolo dei gradienti dei parametri di una Neural Network. Questa attraversa la rete in ordine inverso rispetto alla Forward Propagation partendo quindi dall'Output Layer (la Loss) e andando verso l'Input Layer applicando la Chain Rule.

Sia $J = L + s$ l'Objective Function, vogliamo calcolare le derivate parziali di J rispetto a ciascun parametro della rete $\mathbf{W}^{(1)}$ e $\mathbf{W}^{(2)}$. Vediamo quindi in ordine i passaggi della backpropagation.

...

11.4. Training Neural Networks

Durante il training di una rete neurale, le due propagation sono strettamente interdipendenti. La Forward calcola il valore delle loss e salva in memoria tutte le variabili intermedie, la backward utilizza questi valori intermedi per valutare le derivate parziali e calcolare i gradienti tramite la Chain Rule. È per questo che l'addestramento richiede molta più memoria dell'inferenza, durante quest'ultima infatti non abbiamo bisogno di memorizzare tutti i valori intermedi.

12. Numerical Stability and Initialization

Quando addestriamo reti con decine o centinaia di strati, la stabilità numerica dell'algoritmo di Backpropagation diventa un fattore critico. Scelte errate nell'architettura o nell'inizializzazione dei pesi possono far sì che i gradienti o le attivazioni intermedie crescano a dismisura fino all'overflow oppure svaniscano fino a zero (underflow). Esaminiamo quindi i due problemi principali – **Vanishing Gradients** e **Exploding Gradients** – per poi analizzare le strategie di **Parameter Initialization** progettate per garantire un addestramento stabile.

Consideriamo una Deep Neural Network con L Hidden Layers. Durante il passaggio di Backpropagation, il gradiente della Loss Function rispetto ai pesi dei primi strati comporta la moltiplicazione a catena di L matrici di pesi e di derivate delle Activation Functions

$$\partial_{\mathbf{W}^{(1)}} J \propto \mathbf{M}^{(L)} \mathbf{M}^{(L-1)} \dots \mathbf{M}^{(2)}$$

Dove ciascuna matrice $\mathbf{M}^{(l)}$ dipende dalla matrice dei pesi $\mathbf{W}^{(l)}$ e dalla derivata della Activation Function allo strato l .

Vanishing Gradients - Se i valori all'interno delle matrici o le derivate delle Activation Functions sono sistematicamente minori di 1 allora il prodotto di L di tali fattori decresce esponenzialmente al crescere della profondità di L ; di conseguenza i pesi dei primi strati non ricevono alcun aggiornamento significativo e rimangono bloccati ai loro valori iniziali impedendo l'apprendimento della rete.

Exploding Gradients - Al contrario se i valori dei pesi sono sistematicamente maggiori di 1 allora il prodotto a catena cresce esponenzialmente quindi i gradienti assumono valori enormi causando aggiornamenti instabili ed estremi dei parametri tramite la SGD; inoltre a livello computazionale questo porta ad un overflow della memoria.

12.1. Symmetry Breaking

Un altro problema riguarda la scelta dell'inizializzazione dei parametri, se inizializzassimo tutti i pesi di una Neural Network allo stesso valore costante:

- Durante la Forward Propagation tutti i neuroni di un determinato hidden layer calcolerebbero esattamente lo stesso output intermedio.
- Durante la Backpropagation tutti i neuroni riceverebbero esattamente lo stesso identico gradiente.

Di conseguenza, l'aggiornamento dei parametri farebbe evolvere tutti i neuroni in modo identico. La rete neurale perde la capacità di far specializzare i vari neuroni su feature differenti riducendo l'intera capacità di un hidden layer a quella di un singolo neurone isolato.

12.2. Parameter Initialization Strategies

Per evitare tutti questi problemi, i pesi devono essere inizializzati casualmente ed essere scalati in modo che la varianza delle attivazioni e dei gradienti rimanga costante attraverso tutti gli strati.

Xavier Initialization - È progettata per strati con Activation Functions che si comportano in modo approssimativamente lineare attorno allo zero, come la Tanh. ...

He / Kaiming Initialization - Risponde al fatto che la ReLU annulla esattamente la metà degli input, dimezzando di fatto la varianza del segnale che passa attraverso lo strato. Per compensare questa perdita, la varianza dei pesi viene raddoppiata rispetto alla sola dimensione d'ingresso.

13. Generalization in Deep Learning

Abbiamo visto il concetto di Generalization e dell'Overfitting e anche come il Bias-Variance Trade-off suggerisca un equilibrio: aumentare la capacità del modello dovrebbe, oltre una certa soglia, portare inevitabilmente a un grave overfitting. Tuttavia le reti neurali moderne sfidano questo concetto. Esse sono fortemente overparameterized ovvero possiedono molti più parametri rispetto al numero di campioni nel dataset di addestramento, riescono ad azzerare il training error eppure continuano a mostrare una generalization eccellente nei test.

13.1. Revisiting Overfitting and Regularization

Per comprendere la generalization occorre considerare il teorema *No Free Lunch*. Questo dimostra che nessun algoritmo di apprendimento può superare qualsiasi altro su tutte le possibili distribuzioni di dati. Di conseguenza, ogni modello si basa su specifici bias induttivi ovvero preferenze verso determinate soluzioni che riflettono la struttura del problema da risolvere. Ad esempio, le reti neurali assumono implicitamente che funzioni complesse possano essere descritte tramite la composizione gerarchica di funzioni elementari più semplici.

Il gap di generalizzazione è definito come la differenza tra il training error e il test error, quando questo divario diventa troppo grande il modello si trova in uno stato di overfitting.

A differenza dei modelli statistici tradizionali, le reti neurali profonde possiedono una capacità espressiva talmente elevata da poter interpolare perfettamente qualsiasi dataset di dimensione finita, azzerando il training error anche con etichette casuali. Sorprendentemente l'aumento delle capacità del modello tramite l'aggiunta di strati o parametri non porta necessariamente a un peggioramento delle prestazioni sul test ma anzi, ne aumenta le capacità di generalizzazione. Questo comportamento rende inapplicabili le teorie basate sulla VC dimension le quali prevederebbero un limite teorico di errore piccolo o infinito per modelli fortemente sovrapparametrizzati.

13.2. Inspiration from Nonparametrics

...

13.3. Early Stopping

Nonostante le reti abbiano la capacità teorica di memorizzare dataset rumorosi o del tutto arbitrari, la dinamica temporale dell'addestramento mostra che esse non apprendono tutte le informazioni allo stesso ritmo. Gli studi mostrano che l'algoritmo di ottimizzazione tende ad apprendere prima i pattern generali lasciando la memorizzazione del rumore alle fasi finali.

Questa proprietà giustifica l'utilizzo dell'Early Stopping. Anziché modificare direttamente la loss function aggiungendo termini di penalità sui pesi, si limita il numero di epoche di addestramento. Si valuta costantemente l'errore sul test set e si interrompe la procedura quando le prestazioni sul test set smettono di migliorare dopo un numero predefinito di epoche, preservando così la capacità di generalizzazione del modello prima che subentri la memorizzazione del rumore.

14. Dropout

L'idea del dropout consiste nell'inserire del rumore durante il calcolo di ciascun strato interno nel corso del forward ed è diventata una tecnica standard per l'addestramento delle reti neurali. Il metodo si chiama dropout perchè durante l'addestramento appunto si escludono alcuni neuroni.

Nella regolarizzazione standard con dropout, si azzerava una certa frazione dei nodi in ogni strato e poi si elimina il bias di ogni strato normalizzandolo in base alla frazione di nodi che sono stati mantenuti. In altre parole, con probabilità di dropout p , ogni attivazione intermedia h viene sostituita da una variabile casuale h' definita da:

$$h' = \begin{cases} 0 & \text{with probability } p \\ \frac{h}{1-p} & \text{otherwise} \end{cases}$$

Grazie a questa tecnica, il calcolo dello strato di output non può dipendere eccessivamente da nessun singolo elemento degli hidden layer.

Tipicamente il dropout viene disattivato in fase di test, tuttavia esistono alcune eccezioni. Alcuni ricercatori utilizzano il dropout in fase di test come euristica per stimare l'incertezza delle previsioni della rete neurale, se le previsioni coincidono in molti output diversi generati dal dropout allora si potrebbe affermare che la rete è più sicura delle proprie previsioni. Ovvero che gli output, appunto, non dipendono eccessivamente da neuroni specifici ma qualsiasi spegniamo la rete riesce a generalizzare.

15. Convolutional Neural Networks

Le immagini, come informazione, sono rappresentate da griglie bidimensionali di pixel, sia che questa sia monocoloro o a colori. Di conseguenza, ogni pixel corrisponde rispettivamente a uno o più valori numerici. Finora abbiamo ignorato questa struttura e trattato le immagini come vettori numerici non sfruttando quindi la relazione spaziale tra i pixel. Questo approccio era però necessario per usare gli MLP. Poiché queste reti sono invarianti rispetto all'ordine delle caratteristiche potevamo ottenere risultati simili indipendentemente dal fatto che conservassimo un ordine corrispondente alla struttura spaziale dei pixel o che permutassimo i parametri della MLP. Vorremmo invece sfruttare la nostra conoscenza a priori secondo cui i pixel vicini sono tipicamente correlati tra loro in modo da costruire modelli efficienti per l'apprendimento dei dati dalle immagini.

Vediamo quindi le *Convolutional Neural Networ (CNN)*, una potente famiglia di reti neurali progettate proprio per questo scopo.

Le moderne CNN devono il loro design a spunti tratti dalla biologia, dalla teoria dei gruppi e a una buona dose di sperimentazione pratica. Oltre alla loro efficienza nella realizzazione di modelli, le CNN sono anche efficienti dal punto di vista computazionale, sia perchè richiedono un numero inferiore di parametri rispetto alle fully connected, sia perchè le convoluzioni sono facili da parallelizzare tra i core delle GPU. Di conseguenza gli esperti applicano le CNN ogni volta che è possibile.

15.1. From Fully Connected Layers to Convolutions

Ad oggi, i modelli di cui abbiamo parlato finora sono buoni quando abbiamo a che fare con dati tabulari ovvero dati costituiti da righe corrispondenti agli esempi e colonne per le features. Con i dati tabulari, potremmo prevedere che i modelli che cerchiamo possano comportare interazioni tra le features, ma non ipotizziamo a priori alcuna struttura relativa al modo in cui le features interagiscono. Tuttavia per i dati percettivi ad alta dimensionalità, tali reti prive di struttura possono diventare difficili da gestire.

Ad esempio, tornando all'esempio sulla distinzione fra gatti e cani, supponiamo di svolgere un grande lavoro nella raccolta dei dati ottenendo un set di dati annotato composto da fotografie da un megapixel, quindi ogni input della rete ha un milione di dimensioni. Anche una riduzione a mille dimensioni nascoste richiederebbe un fully connected layer da $10^6 \times 10^3 = 10^9$ parametri. A meno che non si disponga di numerose GPU super ottimizzate, l'apprendimento dei parametri potrebbe essere irrealizzabile.

Si potrebbe pensare che non è necessaria una risoluzione di un Megapixel, tuttavia sebbene potremmo cavarcela con centomila pixel, il nostro hidden layer di dimensione 1000 sottostima il numero di unità nascoste necessarie per apprendere buone rappresentazioni delle immagini, quindi un sistema pratico richiederà comunque miliardi di parametri. Inoltre, l'apprendimento di un classificatore mediante l'adattamento a così tanti parametri potrebbe richiedere la raccolta di un enorme set di dati. Oggi però sappiamo che i computer li distinguono abbastanza bene (cani e gatti). Ciò è dovuto al fatto che le immagini presentano una struttura ricca che può essere sfruttata sia dagli esseri umani che dai modelli di apprendimento. Le CNN rappresentano un approccio creativo adottato dall'apprendimento automatico per sfruttare alcune delle strutture note presenti nelle immagini naturali.

15.2. Invariance

Immaginiamo di voler individuare un oggetto in un'immagine. Sembra ragionevole che, qualunque sia il metodo utilizzato per riconoscere gli oggetti, esso non debba concentrarsi eccessivamente sulla posizione precisa dell'oggetto nell'immagine. Idealmente, il nostro sistema dovrebbe sfruttare questa conoscenza. Di solito i maiali non volano e gli aerei non nuotano. Ciononostante, dovremmo comunque riconoscere un maiale se ne comparisse uno nella parte superiore dell'immagine. Possiamo trarre ispirazione dal gioco «Dov'è Waldo?». Il gioco consiste in una serie di scene caotiche dove Waldo compare da qualche parte, in genere nascosto in luoghi improbabili, l'obiettivo è appunto individuarlo. Nonostante il suo abbigliamento caratteristico ciò può rivelarsi estremamente difficile a causa del gran numero di elementi di distrazione. Tuttavia, l'aspetto di Waldo non dipende dalla sua posizione, potremmo scansionare l'immagine con un «rilevatore di Waldo» in grado di assegnare un punteggio a ciascuna area, indicando la probabilità che tale area contenga Waldo. Infatti, molti algoritmi di rilevamento e segmentazione degli oggetti si basano su questo approccio. Le CNN sistematizzano questa idea di invarianza spaziale, sfruttandola per apprendere rappresentazioni utili con un numero minore di parametri.

Ora possiamo rendere più concrete queste intuizioni elencando alcuni requisiti che guidino la progettazione di un'architettura di rete neurale adatta alla Computer Vision:

1. Nei primi livelli, la nostra rete dovrebbe rispondere in modo simile allo stesso frammento, indipendentemente dalla sua posizione nell'immagine. Questo principio è chiamato *translation invariance*.
2. Gli strati più superficiali della rete dovrebbero concentrarsi sulle regioni locali, senza tenere conto dei contenuti dell'immagine nelle regioni distanti. Questo è il *locality principle*. Infine, queste rappresentazioni locali possono essere aggregate per effettuare previsioni a livello dell'intera immagine.
3. Man mano che procediamo, gli strati più profondi dovrebbero essere in grado di cogliere caratteristiche dell'immagine a più lungo raggio, in modo simile alla visione di livello superiore presente in natura.

Vediamo come convertire tutto questo in linguaggio matematico.

15.3. Constraining the MLP

Per cominciare possiamo considerare un MLP con immagini bidimensionali $\mathbf{X}$ come input e le loro rappresentazioni nascoste immediate $\mathbf{H}$ rappresentate in modo simile tramite matrici dove $\mathbf{X}$ e $\mathbf{H}$ hanno la stessa forma. Immaginiamo ora che non solo gli input ma anche le rappresentazioni nascoste possiedano una struttura spaziale.

Indichiamo con $[\mathbf{X}]_{i,j}$ e $[\mathbf{H}]_{i,j}$ il pixel alla posizione (i, j) nelle rispettive matrici. Per fare in modo che ogni hidden unit riceva input da ogni pixel in input, dobbiamo smettere di usare matrici dei pesi per rappresentare i parametri e dobbiamo usare tensori dei pesi $\mathbf{W}$ di ordine 4. Supponiamo che $\mathbf{U}$ contenga i bias, possiamo quindi esprimere il fully connected layer come:

$$\begin{aligned} [\mathbf{H}]_{i,j} &= [\mathbf{U}]_{i,j} + \sum_k \sum_l [\mathbf{W}]_{i,j,k,l} [\mathbf{X}]_{k,l} \\ &= [\mathbf{U}]_{i,j} + \sum_a \sum_b [\mathbf{V}]_{i,j,a,b} [\mathbf{X}]_{i+a,j+b} \end{aligned}$$

Dove $u_{i,j}$ rappresenta il termine di bias specifico della posizione (i, j) e W é un tensore a 4 dimensioni contenente i pesi che collegano il pixel di input nella posizione (k, l) al nodo nascosto nella posizione (i, j) . Possiamo riformulare l'indicizzazione dei pesi esprimendo la posizione del pixel di input (k, l) come uno spostamento relativo (a, b) rispetto alla posizione di output (i, j) ponendo $k = i + a$ e $l = j + b$.

Applichiamo quindi il primo vincolo: l'Invarianza per Traslazione. Se la risposta del rilevatore non deve dipendere dalla posizione assoluta (i, j) nell'immagine allora i pesi V non devono variare al variare di i, j . Pertanto $V_{i,j,a,b}$ diventa una funzione che dipende esclusivamente dagli offset relativi a e b cioè $[V]_{a,b}$ e il bias diventa una costante unica u :

$$[H]_{i,j} = u + \sum_a \sum_b [V]_{a,b} [X]_{i+a,j+b}$$

Ora applichiamo il secondo vincolo: la località. Se gli unici pixel che influenzano il nodo (i, j) sono quelli situati in un piccolo intorno di raggio D intorno a (i, j) possiamo imporre che $[V]_{a,b} = 0$ per tutti gli offset tali che $|a| > D$ oppure $|b| > D$. L'equazione diventa:

$$[H]_{i,j} = u + \sum_{a=-D}^D \sum_{b=-D}^D [V]_{a,b} [X]_{i+a,j+b}$$

Questa equazione definisce formalmente uno strato convoluzionale. Il tensore V dei pesi non dipende più dalle dimensioni dell'immagine ma solo dalle dimensioni del filtro locale (detto kernel o maschera di convoluzione), riducendo i parametri da ordine $\mathcal{O}(H^2 W^2)$ ad appena $\mathcal{O}(K^2)$ dove $K = 2D + 1$ é la dimensione del kernel.

15.4. Convoluzioni

In matematica la vera operazione di convoluzione bidimensionale tra una funzione discreta X e un kernel V prevede un ribaltamento degli indici. Tuttavia la formula vista prima implementa il segno più negli indici degli input, operazione nota in analisi dei segnali come *cross-correlation*. Nel deep learning si utilizza comunemente il termine «convoluzione» per riferirsi in realtà alla cross-correlazione. Questa imprecisione terminologica non ha alcun impatto pratico sulle prestazioni dell'algoritmo: poichè la matrice del Kernel V viene appresa dai dati tramite la discesa del gradiente, la rete apprenderà automaticamente i pesi ruotati o specchiati se necessario, rendendo l'operazione di ribaltamento matematico del tutto superflua durante il calcolo.

16. Convolutions for Images

Adesso che sappiamo come lavorano le convoluzioni nella teoria vediamole nella pratica.

16.1. The Cross-Correlation Operation

Per ora ignoriamo i canali dell'immagine e vediamo come funzionano con dei dati bidimensionali e la loro hidden representation. L'input è un tensore bidimensionale con un'altezza di 3 e un larghezza di 3. Abbiamo quindi come shape del tensor 3×3 , $(3, 3)$. Sia altezza che larghezza del kernel valgono 2. La shape o la *kernel window* è data dall'altezza e dalla larghezza del kernel, quindi in questo caso 2×2 .

Input		Kernel		Output																	
<table border="1"><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	*	<table border="1"><tr><td>0</td><td>1</td></tr><tr><td>2</td><td>3</td></tr></table>	0	1	2	3	=	<table border="1"><tr><td>19</td><td>25</td></tr><tr><td>37</td><td>43</td></tr></table>	19	25	37	43
0	1	2																			
3	4	5																			
6	7	8																			
0	1																				
2	3																				
19	25																				
37	43																				

Nelle operazioni *cross-correlation* bidimensionali iniziamo con la convolution window posizionata nell'angolo in alto a sinistra dell'input tensor e la spostiamo da sinistra verso destra e dall'alto verso il basso. Quando la convolution window si sposta in una posizione, il subtensor dell'input contenuto in quella finestra e il kernel tensor vengono moltiplicati elementwise e il risultato viene sommato fino ad ottenere un singolo valore scalare. Questo valore sarà il risultato dell'output tensor in quella posizione.

Se la matrice di input possiede un'altezza H e una larghezza W e la matrice del kernel possiede un'altezza k_h e una larghezza k_w , le dimensioni dell'output calcolato saranno pari ad un'altezza di $H - k_h + 1$ ed una larghezza di $W - k_w + 1$.

16.2. Convolutional Layers

Un convolutional layer effettua una cross-correlation tra l'input e il kernel e aggiunge un bias scalare per produrre un output. I due parametri di un convolutional layer sono il kernel e il bias scalare. Quando si addestrano modelli basati su convolutional layer tipicamente si inizializzano i kernel in modo randomico.

16.3. Feature Map and Receptive Field

La matrice bidimensionale prodotta in uscita da un convolutional layer prende il nome di *feature map*, indicando che ogni suo elemento rappresenta l'attivazione di uno specifico rilevatore di strutture estratte dal livello sottostante.

Per un qualsiasi elemento appartenente a una feature map situata ad un certo livello della rete, si definisce *receptive field* l'insieme di tutti i pixel e di tutti gli elementi dei livelli precedenti che hanno contribuito a determinare il valore di quell'elemento. Il receptive field si espande progressivamente man mano che ci si addentra nella profondità dell'architettura. Se si applica un primo kernel di dimensione 3×3 su un'immagine d'ingresso, ogni elemento della prima feature map possiede un receptive field di dimensione 3×3 . Applicando un secondo strato convoluzionale con un ulteriore kernel 3×3 al di sopra di questa mappa, ogni elemento del secondo livello possiederà un receptive field pari a 5×5 pixel dell'immagine originale di partenza. La sovrapposizione di più strati


convoluzionali con filtri piccoli permette di catturare dipendenze spaziali sempre più ampie mantenendo un numero ridotto di parametri.

17. Padding and Stride

Vedremo alcune tecniche che ci garantiscono più controllo sulla dimensione dell'output. Notiamo infatti che siccome i kernel hanno larghezza e altezza maggiore di 1 (di solito), dove averne applicati alcuni finiamo per avere un output molto più piccolo rispetto all'input originale. Se iniziamo con una foto 240×240 pixel e applichiamo 10 layer convoluzionali 5×5 riduciamo l'immagine a 200×200 tagliando il 30% dell'immagine e ignorando ogni informazione presente ai bordi di questa. Il *padding* è lo strumento più conosciuto per risolvere questo problema. In altri casi potremmo invece voler ridurre drasticamente la dimensionalità, le convoluzioni con stride variabile sono una tecnica molto diffusa che può rivelarsi utile in questi casi.

17.1. Padding

Abbiamo detto appunto che i pixel ai bordi dell'immagine vengono persi quando applichiamo dei convolutional layer, vediamo un esempio:



L'immagine ci mostra quante volte i pixel vengono riutilizzati con rispettivamente dei kernel grandi 1×1 , 2×2 , 3×3 .

Una soluzione semplice è quella di aggiungere dei pixel ai bordi dell'immagine tipicamente impostandoli a 0. Nelle CNN di solito si utilizzano finestre dei kernel e padding dispari per produrre output della stessa grandezza dell'input.

17.2. Stride

Di base quando facciamo i calcoli per i convolutional layer ci spostiamo di una posizione alla volta. Tuttavia a volte sia per motivi di efficienza sia perché desideriamo effettuare un downsampling, spostiamo la finestra di più di un elemento alla volta saltando le posizioni intermedie. Ciò è particolarmente utile se il kernel di convoluzione è di grandi dimensioni, poiché cattura un'ampia area dell'immagine sottostante.

Il numero di righe e colonne attraversate per ogni scorrimento viene definito *stride*. Possiamo effettuare degli stride sia sulle righe che sulle colonne e anche di dimensioni diverse fra loro.


18. Multiple Input and Multiple Output Channels

Per ora abbiamo sempre assunto che le immagini in input avessero sempre e solo un canale tuttavia le immagini reali sono quasi sempre caratterizzate da più canali d'ingresso come ad esempio le classiche immagini RGB.

18.1. Multiple Input Channels

Quando i dati di input contengono più canali d'ingresso occorre costruire un kernel convoluzionale con il medesimo numero di canali di input. Denotando con C_{in} il numero di canali d'ingresso dell'immagine, il filtro deve essere rappresentato da un tensore tridimensionale composto da C_{in} matrici bidimensionali di pesi. Per calcolare il risultato dell'operazione si esegue l'operazione di cross-correlation bidimensionale separatamente su ciascun canale, applicando la specifica matrice bidimensionale del kernel al relativo canale dell'input. Successivamente, si sommano elemento per elemento le C_{in} matrici risultanti per ottenere un'unica matrice bidimensionale di output.

Dal punto di vista matematico se l'input X ha dimensione $C_{in} \times H \times W$ e il kernel K ha dimensione $C_{in} \times k_h \times k_w$, l'operazione di cross-correlation produce un output bidimensionale di dimensione $(H - k_h + 1) \times (W - k_w + 1)$. In questo processo, le caratteristiche spaziali di ciascun canale d'ingresso vengono elaborate e fuse lungo la dimensione dei canali attraverso la somma pesata dei contributi individuali.




18.2. Multiple Output Channels

Indipendentemente dal numero di canali in ingresso, l'utilizzo di un singolo set di filtri tridimensionali produce sempre una feature map bidimensionale a singolo canale. Tuttavia, nelle architetture reali è fondamentale apprendere molteplici rilevatori di struttura a ciascun livello per estrarre diverse tipologie di informazioni. Per generare un output contenente C_{out} canali definiamo un tensore dei pesi del kernel quadridimensionale dotato di forma $C_{out} \times C_{in} \times k_h \times k_w$. Ciascuno dei C_{out} canali d'uscita possiede un proprio set di filtri di dimensione $C_{in} \times k_h \times k_w$

18.3. 1×1 Convolutional Layer

Un convolutional layer con dimensione del kernel 1×1 sembra privo di senso. Poichè la finestra ha dimensione $k_h = k_w = 1$ non aggrega informazioni provenienti dai pixel vicini, tuttavia, svolge un ruolo essenziale combinando le informazioni lungo la dimensione dei canali. Posizionando il kernel 1×1 su una determinata posizione, l'operazione esegue il prodotto scalare tra il vettore delle attivazioni di input di lunghezza presenti in quel singolo pixel e il vettore dei pesi del kernel.

Di conseguenza una convoluzione 1×1 equivale ad applicare un MLP fully connected in modo indipendente ed identico su ogni singolo pixel dell'immagine. Gli unici parametri appresi sono le combinazioni lineari tra i canali di input. Questa proprietà rende le convoluzioni 1×1 uno strumento potente e computazionalmente efficiente per modificare, ridurre o espandere il numero dei canali introducendo al contempo funzioni di attivazione non lineari senza alterare la risoluzione dell'immagine.



19. Pooling

In alcuni casi il nostro obiettivo è quello di ottenere delle informazioni dall'immagine *globale*, come ad esempio, «contiene un gatto?», di conseguenza le unità nel nostro layer finale devono essere sensibili all'intero input. Aggregando gradualmente le informazioni, ottenendo mappe sempre più grossolane, raggiungiamo questo obiettivo di apprendere, in ultima analisi, una rappresentazione globale, pur mantenendo tutti i vantaggi degli strati convoluzionali negli strati intermedi dell'elaborazione. Più ci addentriamo nella rete, più ampio è il receptive field rispetto all'input a cui è sensibile ciascun nodo nascosto. La riduzione della risoluzione spaziale accelera questo processo, poichè i kernel di convolution coprono un'area effettiva più ampia.

Inoltre, quando si individuano features a livello inferiore come i bordi, spesso vogliamo che le rappresentazioni siano in qualche modo invarianti rispetto alla traslazione. Ad esempio, se prendiamo l'immagine X con una netta delimitazione tra bianco e nero e spostiamo l'intera immagine di un pixel a destra, l'output per la nuova immagine Z potrebbe risultare diverso. Il bordo si sarà spostato di un pixel.

Introduciamo quindi i *pooling layers*, servono a ridurre la sensibilità dei layer convoluzionali alla posizione e servono anche ad effettuare un downsampling spaziale delle rappresentazioni.

19.1. Maximum Pooling and Average Pooling


Anche i pooling layers consistono di una window di forma fissa che viene fatta scorrere sull'immagine calcolando un unico valore per ciascuna posizione attraversata, anche chiamata *pooling window*. Tuttavia, a differenza dei convolutional kernel, quelli di pooling non hanno parametri (quindi non c'è un kernel). Gli operatori di pooling sono deterministici e calcolano tipicamente il valore massimo o quello medio degli elementi presenti nella finestra di pooling. Queste operazioni sono denominate rispettivamente *maximum pooling* e *average pooling*.

20. Convolutional Neural Networks (LeNet)

Combiniamo tutto quello che abbiamo visto per costruire una LeNet, una delle prime reti neurali convoluzionali per il riconoscimento delle cifre manoscritte nei servizi postali. La nascita di LeNet ha dimostrato empiricamente che l'integrazione di strati convoluzionali e strati di pooling consente di superare i limiti degli MLP nell'elaborazione delle immagini.

20.1. LeNet

Questa architettura è composta da 2 parti fondamentali, un blocco convoluzionale iniziale dedicato all'estrazione delle features visive e un blocco fully connected finale dedicato alla classificazione.



Il blocco convoluzionale è organizzato in una struttura sequenziale che alterna due strati convoluzionali e due strati di sottocampionamento o pooling. Il primo strato convoluzionale accetta in ingresso un'immagine a canale singolo e applica sei filtri con kernel di dimensione 5×5 e un padding di due pixel. Successivamente viene applicata una funzione di attivazione non lineare e uno strato di average pooling con finestra di dimensione 2×2 e stride pari a due, che dimezza sia l'altezza che la larghezza delle feature maps.

Il secondo strato convoluzionale accetta le sei feature maps risultanti dal primo blocco e applica 16 filtri con kernel 5×5 senza padding, riducendo le dimensioni spaziali. Segue un secondo strato di attivazione non lineare e un ulteriore strato di average pooling 2×2 con stride 2, che riduce ulteriormente le dimensioni delle feature map in output.

Alla fine del blocco convoluzionale, le feature map bidimensionali risultanti di dimensione 16×5 vengono appiattite in un unico vettore monodimensionale di 400 elementi. Questo vettore viene passato al blocco completamente connesso, costituito da un primo strato denso con 120 unità, un secondo strato denso con 84 unità e uno strato di output finale con 10 unità, corrispondenti alle 10 classi di cifre o oggetti da classificare.

21. Batch Normalization

L'addestramento delle reti neurali presenta sfide complesse legate alla stabilizzazione della dinamica dei gradienti e alla convergenza dell'ottimizzazione. Man mano che una rete accumula strati, le variazioni nei parametri dei primi livelli alterano la distribuzione delle attivazioni inviate ai livelli successivi. Per affrontare questa problematica è stata introdotta la tecnica della *Batch Normalization*. Questa ha permesso di addestrare architetture molto più profonde con tassi di apprendimento elevati e fornendo una convergenza notevolmente più rapida.

21.1. Training Deep Networks

Quando si adotta la discesa del gradiente stocastica su mini-batch per ottimizzare i parametri, l'aggiornamento dei pesi di un layer intermedio influisce sulla distribuzione delle uscite che lo stesso strato trasmette al livello successivo. Se gli strati precedenti modificano continuamente la propria rappresentazione, gli strati successivi devono adattarsi costantemente a un input la cui media e la cui varianza oscillano nel corso dell'addestramento. Tali oscillazioni rallentano l'ottimizzazione e costringono a impiegare passi estremamente ridotti.

La Batch Normalization affronta questa criticità standardizzando le attivazioni intermedie all'interno di ciascun mini-batch. Consideriamo un vettore di attivazioni x generato da un campione all'interno di un mini-batch B . La procedura calcola innanzitutto la media campionaria e la varianza campionaria del mini-batch lungo la dimensione del batch.

22. Computer Vision

22.1. Image Aumentation

Abbiamo visto come grandi dataset sono un prerequisito per il successo delle reti neurali. L'aumento delle immagini genera esempi di addestramento simili ma distinti dopo una serie di modifiche casuali alle immagini di addestramento, ampliando così la dimensione del set di addestramento. Ad esempio, possiamo ritagliare un'immagine in modi diversi per far apparire l'oggetto di interesse in posizioni diverse, riducendo così la dipendenza di un modello dalla posizione dell'oggetto. Possiamo anche regolare fattori quali la luminosità e il colore per ridurre la sensibilità di un modello al colore.

22.1.1. Common Image Augmentation Methods

22.1.1.1. Flipping and Cropping

Flippare l'immagine a destra e sinistra non cambia la categoria dell'oggetto, questo è uno dei primi metodi di augmentation, di base cerchiamo di farla nel 50% dei casi di esempio. Un'altra tecnica invece è quella di ritagliare l'immagine per far apparire l'oggetto da riconoscere in punti diversi.

22.1.1.2. Changing Colors

Possiamo cambiare 4 valori dell'immagine: luminosità, contrasto, saturazione e tonalità.

22.1.1.3. Combining Multiple Image Augmentation Methods

Di solito si combinano più tecniche ...

Questo si fa principalmente durante il training del modello e non durante l'inferenza.

22.2. Fine-Tuning

Spesso nelle applicazioni di Computer Vision ci si trova a dover risolvere problemi di classificazione delle immagini su dataset di dimensioni ridotte. Se si tentasse di addestrare una rete neurale complessa da zero su poche centinaia di immagini, il modello andrebbe incontro ad un grave overfitting a causa dell'enorme differenza tra il numero di parametri della rete e il numero ridotto di esempi.

Per superare questo ostacolo, la pratica standard nel deep learning si avvale del *transfer learning*. L'idea fondamentale consiste nel prendere un modello addestrato su un dataset enorme e trasferire la conoscenza appresa su un compito specifico caratterizzato da un dataset più piccolo. La tecnica di transfer learning più diffusa ed efficace è il *fine-tuning*.

22.2.1. Passaggi del Fine-Tuning

La procedura di fine-tuning è composta da 4 fasi:

1. **Pre-addestramento sul modello sorgente:** Si addestra una rete neurale su un grande dataset per consentire all'architettura di apprendere rappresentazioni visive di carattere generale come bordi, trame, forme ecc...
2. **Copia dell'architettura e dei pesi:** Si crea un nuovo modello di rete neurale copiando la struttura e tutti i parametri appresi dal modello sorgente con l'unica eccezione dello strato finale di output.

3. **Inizializzazione dello strato di output:** Si aggiunge al modello target un nuovo strato di output la cui dimensione corrisponde esattamente al numero di classi presenti nel dataset target e se ne inizializzano i pesi in modo casuale.
4. **Addestramento sul dataset target:** Si addestra l'intera rete target sul nuovo dataset. In questa fase, lo strato di output viene ottimizzato a partire da zero, mentre i parametri di tutti gli strati precedenti vengono affinati a partire dai pesi ereditati dal modello sorgente.

Da notare inoltre che l'addestramento della nuova rete richiede una gestione attenta del learning rate. Poichè lo strato d'uscita è stato inizializzato casualmente, i suoi pesi necessitano di un tasso di apprendimento relativamente elevato per convergere rapidamente. Al contrario gli strati convoluzionali pre-addestrati contengono già rappresentazioni visive di alta qualità, pertanto i loro pesi devono essere aggiornati con un tasso di apprendimento significativamente più piccolo. Impostare un tasso di apprendimento piccolo sugli strati convoluzionali serve appunto a non distruggere le features generali già apprese.

22.3. Object Detection and Bounding Boxes

Ci siamo sempre concentrati in problemi di classificazione ovvero identificare la categoria dell'oggetto contenuto nell'immagine. Tuttavia, in numerose applicazioni è indispensabile determinare non solo quale oggetto è presente ma anche individuare la posizione esatta di ciascun oggetto all'interno della scena. Questo compito prende il nome di *object detection*.

Nel rilevamento degli oggetti, la rete deve identificare simultaneamente tutte le regioni di interesse d'impatto semantico e predire per ciascuna di esse sia la classe di appartenenza sia la delimitazione spaziale. La posizione e l'estensione spaziale di un oggetto vengono descritte matematicamente tramite un *bounding box*, ovvero un rettangolo orientato in modo parallelo agli assi dell'immagine che racchiude esattamente i contorni esterni dell'oggetto identificato. Un bounding box può essere rappresentato numericamente attraverso due convenzioni o formati:

1. **Corner Format:** Il rettangolo viene definito specificando le coordinate spaziali dell'angolo in alto a sinistra e dell'angolo in basso a destra.
2. **Center Format:** Il rettangolo viene definito specificando le coordinate del suo punto centrale, unitamente al valore della sua larghezza w e della sua altezza h .

Le coordinate possono essere convertite analiticamente da un formato all'altro mediante semplici trasformazioni algebriche. Dato un bounding box espresso in corner format $(x_{\min}, y_{\min}, x_{\max}, y_{\max})$, la conversione nel center format $(x_{\text{center}}, y_{\text{center}}, w, h)$ si calcola come:

$$x_{\text{center}} = \frac{x_{\min} + x_{\max}}{2}, \quad y_{\text{center}} = \frac{y_{\min} + y_{\max}}{2}$$

$$w = x_{\max} - x_{\min}, \quad h = y_{\max} - y_{\min}$$

Viceversa ...

Un aspetto fondamentale per la loro rappresentazione, riguarda la scala delle coordinate. Le coordinate dei bounding box possono essere espresse in valori assoluti in pixel oppure in valori normalizzati nell'intervallo $[0, 1]$.

La normalizzazione si ottiene dividendo le coordinate orizzontali e la larghezza per la larghezza totale dell'immagine W e le coordinate verticali e l'altezza per l'altezza totale dell'immagine H . Utilizzare coordinate normalizzate rende la rappresentazione geometrica

invariante rispetto alle variazioni di risoluzione o al ridimensionamento dell'immagine in input.

22.4. Anchor Boxes

Gli algoritmi di object detection campionano solitamente un elevato numero di regioni all'interno dell'immagine d'ingresso, determinano se tali regioni contengono oggetti di interesse e aggiustano progressivamente i confini di ciascuna regione per predire con accuratezza i bounding boxes reali. Le regioni di riferimento campionate preventivamente prendono il nome di *anchor boxes*.

Si consideri un'immagine d'ingresso di altezza h e larghezza w . Supponiamo di voler generare anchor box aventi dimensioni e proporzioni differenti centrati su ciascun pixel dell'immagine.

Siano $s \in (0, 1]$ la scala dell'anchor box rispetto all'immagine e $r > 0$ l'aspect ratio (rapporto fra larghezza e altezza). La larghezza e l'altezza dell'anchor box vengono calcolate come:

$$w_{\text{anchor}} = w \cdot s\sqrt{r}, \quad h_{\text{anchor}} = h \cdot \frac{s}{\sqrt{r}}$$

Se definiamo un insieme di n scale distinte $S = \{s_1, \dots, s_n\}$ e un insieme di m rapporti di formati distinti $R = \{r_1, \dots, r_m\}$, la combinazione esaustiva di tutte le scale e di tutti i rapporti di forma su ciascun pixel genererebbe un totale di $h \cdot w \cdot n \cdot m$ anchor box. Per un'immagine ad alta risoluzione, questo numero diventa eccessivamente elevato, comportando un costo computazionale insostenibile.

Per ridurre la complessità mantenendo un'adeguata copertura spaziale, si adotta solitamente la tecnica di combinazione ristretta: si combinano tutte le scale $s_1, \dots, s_n$ esclusivamente con il primo rapporto di forma r_1 e tutti i rapporti di forma $r_1, \dots, r_m$ esclusivamente con la prima scala s_1 .

...

22.4.1. Intersection over Union (IoU)


Per valutare quantitativamente il grado di sovrapposizione geometrica tra un anchor box generato A e un bounding box reale di riferimento B , si utilizza la metrica **Intersection over Union (IoU)**, nota anche come *indice di Jaccard*. L'IoU è definita come il rapporto tra l'area dell'intersezione dei due rettangoli e l'area della loro unione: $J(A, B) = \frac{\text{Area}(A \cap B)}{\text{Area}(A \cup B)}$

L'IoU assume valori compresi nell'intervallo $[0, 1]$:

- Un valore pari a 0 indica l'assenza completa di sovrapposizione tra i due box.
- Un valore pari a 1 indica una sovrapposizione perfetta e coincidente delle due regioni.

22.5. Semantic Segmentation

Per ora abbiamo affrontato soltanto il problema della classificazione delle immagini e il rilevamento di oggetti. Tuttavia esistono numerosi applicazioni nelle quali delimitare un oggetto tramite un rettangolo risulta del tutto insufficiente. In questi ambiti è indispensabile determinare i contorni esatti e la categoria di ciascun singolo pixel dell'immagine. Questo compito prende il nome di *image segmentation*.



22.5.1. Image Segmentation and Instance Segmentation


È fondamentale distinguere tra tre concetti distinti che appartengono alla famiglia della segmentazione:

1. **Image Segmentation:** Rappresenta il processo generico di partizionamento di un'immagine d'ingresso in molteplici regioni disgiunte basandosi su criteri di omogeneità cromatici, di tessitura o di luminanza. Questo approccio tradizionale non assegna necessariamente un significato alle regioni individuate.
2. **Semantic Segmentation:** Consiste nel classificare ciascun pixel dell'immagine assegnandolo a una determinata categoria semantica (persona, autotreno, cane, gatto, sfondo ecc...). Un aspetto caratteristico della segmentazione semantica è che essa **non distingue** tra istanze individuali della medesima categoria. Se all'interno dell'immagine sono presenti cinque persone distinte, tutti i pixel appartenenti a ciascuna di esse verranno contrassegnati con il medesimo valore di classe intero corrispondente alla categoria persona.
3. **Instance Segmentation:** Fusione tra il rilevamento degli oggetti e la segmentazione semantica. non soltanto individua la classe di appartenenza di ciascun pixel ma separa e distingue nettamente ogni singola istanza individuale appartenente alla medesima categoria. Riprendendo l'esempio precedente quindi la segmentazione delle istanze assegnerà etichette distinte ai pixel delle cinque persone.

22.5.2. The Pascal VOC2012 Semantic Segmentation Dataset

Uno dei dataset più importanti per la segmentazione semantica è il Pascal VOC2012. In questo caso le label non sono dei semplici numeri ma sono anch'esse delle immagini dove ogni pixel prende un colore e quel colore indica di cosa fa parte quel pixel.

Avremo quindi un colore per lo sfondo e uno per ogni classe di oggetti, più un altro colore speciale utilizzato come delimitatore fra le classi.



22.5.3. Mappatura dalla Color Map agli Indici di Classe

Per poter essere elaborata da una rete neurale, la maschera di etichetta in input espressa come immagine RGB $H \times W \times 3$ deve essere convertita in una matrice bidimensionale di interi $H \times W$ in cui il valore di ciascun elemento compreso nell'intervallo $[0, 20]$ corrisponde direttamente all'indice numerico della classe semantica associata. Questa trasformazione viene realizzata costruendo una lookup table che mappa in modo biunivoco ciascuna tripletta di valori cromatici nell'indice intero corrispondente.

22.5.4. Data Augmentation

Durante la fase di caricamento dei dati per la segmentazione semantica, le tecniche tradizionali di ridimensionamento e augmentation presentano una complessità aggiuntiva rispetto alla semplice classificazione.

Se si applica un'operazione di ridimensionamento con interpolazione bilineare su un'immagine di maschera contenente indici discreti, l'interpolazione genererà valori intermedi non esistenti. Di conseguenza, nelle pipeline di addestramento per la segmentazione semantica:

1. L'immagine di input originale viene ridimensionata mediante interpolazione bilineare, mentre la maschera viene ridimensionata esclusivamente mediante *Nearest Neighbor Interpolation*.
2. Per evitare di alterare le proporzioni degli oggetti, per fare data augmentation si utilizza il *random cropping*. Questa operazione deve essere eseguita in modo sincronizzato sia sull'immagine di input sia sulla maschera, ritagliando esattamente la medesima regione da entrambe le matrici.

22.6. Transposed Convolution

Abbiamo visto come le CNN riducano progressivamente la risoluzione spaziale delle feature map mediante l'impiego di strati convoluzionali con stride superiore a uno o strati di pooling. Questa contrazione spaziale consente alla rete di espandere il receptive field delle unità e di estrarre rappresentazioni semantiche ad alto livello d'astrazione.

Tuttavia in compiti come la segmentazione semantica è indispensabile compiere il percorso inverso ovvero incrementare la risoluzione spaziale di una feature map a bassa risoluzione per ripristinare le dimensioni originali dell'immagine in input.


L'operazione standard ideata per eseguire questo sovracampionamento apprendibile prende il nome di *transposed convolution*.

22.6.1. Operazione di Base

Mentre una convoluzione standard riduce o mantiene la dimensione spaziale sommando i prodotti pesati degli elementi coperti dal kernel in un singolo valore d'uscita, la convoluzione trasposta funziona espandendo ciascun elemento dell'input attraverso il filtro.

Nella sua forma bidimensionale, data una matrice d'ingresso di dimensione $H_{\text{in}} \times W_{\text{in}}$ e un kernel di dimensione $k_h \times k_w$:

1. Si prende ciascun singolo elemento scalare dell'input e lo si moltiplica elemento per elemento per l'intera matrice del kernel.
2. Si colloca la matrice $k_h \times k_w$ risultante nella corrispondente posizione della griglia d'uscita.
3. Le regioni sovrapposte generate dal calcolo dei diversi elementi dell'input vengono sommate tra loro elemento per elemento.



22.6.2. Padding, Strides e Canali Multipli

Gli hyperparameters di padding e stride nella convoluzione trasposta regolano l'espansione spaziale dell'output, ma agiscono in modo inversamente speculare rispetto alla convoluzione standard.

Nella convoluzione trasposta il padding viene interpretato come il numero di righe e colonne rimosse dai bordi esterni del risultato finale dell'output. Se si applica un padding p_h sulle righe e p_w sulle colonne, la dimensione dell'output si riduce di $2p_h$ in altezza e $2p_w$ in larghezza.

Lo stride invece nella convoluzione trasposta determina il fattore di incremento spaziale dell'output. Se si applica uno stride s_h sulle righe e s_w sulle colonne, l'operazione posiziona le sottomatrici risultanti dalla moltiplicazione del kernel a una distanza di s_h righe e s_w colonne l'una dall'altra nell'output. Equivalentemente, questo corrisponde all'inserimento di $s - 1$ zeri tra gli elementi adiacenti dell'input prima di applicare la convoluzione.

22.6.3. Canali Multipli

Quando l'input comprende C_{in} canali in input e si desiderano produrre C_{out} canali d'uscita, la struttura del tensore dei pesi del kernel ha forma $C_{in} \times C_{out} \times k_h \times k_w$. Si noti la differenza di ordinamento rispetto alla convoluzione standard. Per ciascun canale d'uscita, risultati parziali calcolati su tutti i canali d'ingresso vengono sommati.

22.6.4. Origine del termine

Il termine «Convoluzione Trasposta» deriva dal fatto che questa operazione equivale a moltiplicare il vettore input per la matrice trasposta dei pesi di una corrispondente convoluzione standard. Ma è anche importante sottolineare che la convoluzione trasposta non è l'inversa matematica della convoluzione standard.